

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN TỐT NGHIỆP

**ỨNG DỤNG MÔ HÌNH DEEPLABV3+ KẾT HỢP VỚI THUẬT
TOÁN SVM TRONG CHUẨN ĐOÁN BỆNH DẠ DÀY**

GIẢNG VIÊN HƯỚNG DẪN : THS. NGUYỄN THIÊN DƯƠNG

HỌ TÊN SINH VIÊN : NGUYỄN THỊ TƯỜNG VI

MÃ SỐ SINH VIÊN : 6351071077

LỚP : CQ.63.CNTT

TP. Hồ Chí Minh, tháng 06 năm 2026

NHIỆM VỤ THIẾT KẾ TỐT NGHIỆP
BỘ MÔN: CÔNG NGHỆ THÔNG TIN

-----***-----

Mã sinh viên: 6351071077

Họ và tên SV: Nguyễn Thị Tường Vi

Khóa: 63

Lớp: Công nghệ thông tin

NỘI DUNG

1. Tên đề tài: Ứng dụng mô hình Deeplabv3+ kết hợp với thuật toán SVM trong chuẩn đoán bệnh dạ dày.

2. Mục đích , mục tiêu thực hiện:

Trong những năm gần đây, số lượng người mắc các bệnh liên quan đến dạ dày và đường tiêu hóa ngày càng gia tăng. Việc phát hiện sớm các tổn thương thông qua hình ảnh nội soi đóng vai trò quan trọng trong quá trình chẩn đoán và điều trị. Tuy nhiên, việc quan sát và đánh giá hình ảnh vẫn phụ thuộc nhiều vào kinh nghiệm của bác sĩ chuyên khoa. Xuất phát từ thực tế đó, đề tài được thực hiện với mong muốn tìm hiểu và ứng dụng các kỹ thuật trí tuệ nhân tạo vào lĩnh vực hỗ trợ chẩn đoán y khoa.

Mục tiêu của đề tài là xây dựng một hệ thống có khả năng phân tích hình ảnh nội soi, xác định vùng nghi ngờ tổn thương và đưa ra kết quả dự đoán bệnh tương ứng. Bên cạnh việc nghiên cứu mô hình học máy và học sâu, đề tài còn hướng đến việc phát triển một ứng dụng web giúp người dùng có thể tải ảnh lên và nhận kết quả dự đoán một cách trực quan, thuận tiện cho quá trình trải nghiệm và đánh giá hệ thống.

3. Nội dung và phạm vi đề tài:

Đề tài tập trung nghiên cứu việc ứng dụng trí tuệ nhân tạo vào bài toán hỗ trợ nhận diện bệnh lý dạ dày thông qua hình ảnh nội soi. Nội dung chính của đề tài bao gồm việc tìm hiểu các đặc điểm của ảnh nội soi tiêu hóa, thu thập và tiền xử lý dữ liệu, xây dựng mô hình học sâu DeepLabV3+ để xác định và phân đoạn các vùng nghi ngờ tổn thương trên ảnh. Trên cơ sở đó, các đặc trưng thu được sẽ được sử dụng làm đầu vào cho thuật toán SVM nhằm thực hiện phân loại và đưa ra kết quả dự đoán bệnh.

Bên cạnh việc nghiên cứu và xây dựng mô hình, đề tài còn phát triển một ứng dụng web cho phép người dùng tải lên hình ảnh nội soi, thực hiện phân tích tự động và hiển thị kết quả dự đoán trực quan. Hệ thống được thiết kế theo hướng đơn giản, dễ sử dụng, phục vụ mục đích nghiên cứu và minh họa khả năng ứng dụng của trí tuệ nhân tạo trong lĩnh vực hỗ trợ chẩn đoán y khoa.

Về phạm vi, đề tài chỉ tập trung xử lý ảnh nội soi dạ dày được thu thập từ bộ dữ liệu uy tín được gán nhãn bởi các bác sĩ chuyên khoa để phục vụ nghiên cứu. Hệ thống được xây dựng nhằm hỗ trợ nhận diện và dự đoán một số nhóm bệnh hoặc tổn thương phổ biến có trong tập dữ liệu. Do giới hạn về thời gian, nguồn dữ liệu và năng lực tính toán, đề tài chưa xem xét đến việc triển khai trên môi trường bệnh viện thực tế, chưa tích hợp với các hệ thống y tế chuyên dụng và không thay thế vai trò chẩn đoán của bác sĩ. Kết quả từ hệ thống chỉ mang tính chất tham khảo, hỗ trợ quá trình đánh giá hình ảnh nội soi.

4. Công nghệ, công cụ và ngôn ngữ lập trình

4.1 Công nghệ đã dùng

Frontend được xây dựng bằng React kết hợp Vite. React được dùng để xây dựng giao diện người dùng, quản lý các thành phần như form nhập thông tin bệnh nhân, khu vực upload ảnh, hiển thị kết quả AI, lịch sử hồ sơ và chức năng xem/tải PDF. Vite được sử dụng để chạy môi trường phát triển frontend nhanh hơn và hỗ trợ build ứng dụng.

Backend được xây dựng bằng FastAPI. Backend có nhiệm vụ nhận ảnh từ frontend, kiểm tra file đầu vào, tiền xử lý ảnh, gọi mô hình AI và trả kết quả về cho giao diện. Uvicorn được sử dụng làm server để chạy ứng dụng FastAPI.

Trí tuệ nhân tạo được triển khai bằng PyTorch và TensorFlow/Keras. Trong hệ thống, mô hình ResNet50 được dùng cho bài toán phân loại ảnh nội soi, còn mô hình DeepLabv3+ được dùng cho bài toán phân đoạn vùng polyp. Pillow và NumPy được dùng để đọc ảnh, xử lý ảnh, chuyển đổi dữ liệu và tạo mask/overlay

4.2 Công cụ:

- Visual Studio Code: môi trường viết code và chỉnh sửa project
- React: môi trường chạy frontend
- Python 3.11: môi trường chạy backend và mô hình AI
- Google Colab: huấn luyện mô hình DeepLabv3+ trên GPU
- Trình duyệt web: kiểm thử giao diện người dùng.

5. Các kết quả chính dự kiến sẽ đạt được và ứng dụng:

Qua quá trình nghiên cứu và hoàn thiện, kết quả mong muốn của đề tài là xây dựng được một mô hình có khả năng phát hiện vùng bất thường trên ảnh nội soi và hỗ trợ phân loại bệnh với độ chính xác phù hợp trên bộ dữ liệu thử nghiệm. Đồng thời, đề tài hướng đến việc hoàn thiện một ứng dụng web cho phép người dùng tải ảnh nội soi lên hệ thống, xem kết quả dự đoán và hình ảnh trực quan của vùng tổn thương được phát hiện.

Thông qua quá trình thực hiện, đề tài góp phần làm rõ khả năng ứng dụng của trí tuệ nhân tạo trong lĩnh vực y tế, đặc biệt là trong việc hỗ trợ phân tích hình ảnh nội soi. Kết quả nghiên cứu có thể được sử dụng làm nền tảng cho các hướng phát triển tiếp theo nhằm nâng cao độ chính xác của mô hình cũng như mở rộng phạm vi ứng dụng trong thực tế.

6. Giảng viên và cán bộ hướng dẫn

Họ tên: ThS. Nguyễn Thiện Dương

Đơn vị công tác: Trường đại học giao thông vận tải phân hiệu TP. Hồ Chí Minh

Điện thoại:

Email

Ngày tháng 03 năm 2026

Đã giao nhiệm vụ TKTN

Trưởng BM Công nghệ Thông tin

Giảng viên hướng dẫn

ThS. Trần Phong Nhã

ThS. Nguyễn Thiện Dương

Đã nhận nhiệm vụ TKTN

Sinh viên: Nguyễn Thị Tường Vi

Ký tên:

Điện thoại: 0354640972

Email: tuongvi220204@gmail.com

LỜI CẢM ƠN

Quãng thời gian học tập tại Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh là một hành trình đáng nhớ đối với em. Trong hành trình đó, em may mắn nhận được sự quan tâm, hướng dẫn và hỗ trợ tận tình từ quý thầy cô thuộc Bộ môn Công nghệ Thông tin.

Em xin gửi lời cảm ơn chân thành nhất đến thầy Nguyễn Thiện Dương cùng toàn thể quý thầy cô đã luôn tận tâm giảng dạy, truyền đạt kiến thức và tạo điều kiện để chúng em được học tập, rèn luyện. Không chỉ là những kiến thức chuyên ngành, những lời chỉ dẫn và sự động viên của thầy cô còn giúp em có thêm động lực, sự tự tin và tinh thần trách nhiệm khi bước vào môi trường thực tế.

Trong quá trình thực hiện đồ án tốt nghiệp, em đã cố gắng tìm hiểu, học hỏi và hoàn thành nội dung một cách nghiêm túc nhất. Tuy nhiên, với kiến thức và kinh nghiệm thực tế còn hạn chế, báo cáo chắc chắn vẫn còn những điểm chưa trọn vẹn. Em rất mong nhận được sự góp ý và chỉ dẫn từ thầy cô để em có thể nhìn nhận rõ hơn những thiếu sót của mình, từ đó tiếp tục hoàn thiện bản thân trong học tập và công việc sau này.

Một lần nữa, em xin chân thành cảm ơn quý thầy cô đã luôn đồng hành, tận tình chỉ dạy và hỗ trợ em trong suốt thời gian học tập tại trường.

Em kính chúc quý thầy cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái nhiều thành công trong sự nghiệp trồng người.

Em xin chân thành cảm ơn!

This image shows a blank sheet of white paper with horizontal ruling lines. The lines are evenly spaced and extend across the width of the page. There are no margins, text, or other markings on the paper.

Giảng viên hướng dẫn

vi

MỤC LỤC

NHIỆM VỤ THIẾT KẾ TỐT NGHIỆP.....	i
LỜI CẢM ƠN.....	v
NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN	vi
DANH MỤC CHỮ VIẾT TẮT.....	x
MỞ ĐẦU	1
CHƯƠNG 1. CƠ SỞ LÝ THUYẾT.....	8
1.1 Tổng quan về bệnh dạ dày.....	8
1.2. Mô hình phân đoạn hình ảnh DeepLabv3+	10
1.2.1. Giới thiệu DeepLabv3+	10
1.2.2. Kiến trúc mô hình DeepLabv3+	10
1.2.3. Nguyên lý hoạt động	12
1.2.4. Ưu điểm và nhược điểm của DeepLabv3+.....	13
1.3. Thuật toán học máy Support Vector Machine.....	13
1.3.1 Biểu diễn dữ liệu và nhãn.....	14
1.3.2. Nguyên lý của SVM	14
1.3.3 Vector đặc trưng (Feature Vector)	15
1.3.4 Ý tưởng lề cực đại (Maximum Margin)	15
1.3.5. Lề cứng (Hard Margin) cho dữ liệu khả tách tuyến tính.....	16
1.3.6 Quy trình tổng thể khi áp dụng SVM.....	18
1.3.7 Ưu điểm và nhược điểm	18
CHƯƠNG 2: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	20
2.1 Mô tả bài toán.....	20
2.2. Yêu cầu chức năng	21
2.3. Yêu cầu phi chức năng	22
2.4. Yêu cầu về giao diện	22
2.5. Phân tích và thiết kế mô hình nghiên cứu	23

2.5.1 Dữ liệu đầu vào và đầu ra.....	23
2.5.2 Quy trình xử lý dữ liệu	24
2.6. Thiết kế hệ thống	25
2.7 Thiết kế giao diện	26
2.8 Phân tích về thiết kế UML.....	28
2.8.1. Sơ đồ chức năng BFD	28
2.8.2. Sơ đồ Use Case.....	29
2.9 Nhận xét về thiết kế hệ thống	30
CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ HỆ THỐNG.....	32
3.1 Phân tích dữ liệu nghiên cứu	32
3.1.1 Quy trình xử lý dữ liệu	34
3.1.1.1 Tổng quan pipeline xử lý.....	34
3.1.1.2 Tiền xử lý dữ liệu	35
3.1.1.3. Xử lý mặt nạ và gom nhóm nhãn	36
3.1.1.4. Tăng cường dữ liệu.....	36
3.1.1.5. Trích xuất đặc trưng	36
3.1.1.6. Sinh nhãn phân loại	37
3.2 Xử lý SVM	37
3.3 Xử lý Deeplabv3+	43
KẾT LUẬN VÀ KIẾN NGHỊ.....	46
1. Kết luận.....	46
1.1 Kết luận về mặt lý thuyết.....	46
1.2 Kết luận về mặt thực nghiệm.....	46
2. Hạn chế.....	47
3. Hướng phát triển tương lai	48
TÀI LIỆU THAM KHẢO	50

DANH MỤC CHỮ VIẾT TẮT

STT	Chữ viết tắt	Ý nghĩa
1	AI	Trí tuệ nhân tạo
2	API	Giao diện lập trình ứng dụng
3	ASPP	Atrous Spatial Pyramid Pooling
4	BCE	Binary Cross Entropy
5	BE	Backend, phần xử lý phía máy chủ
6	BFD	Business Function Diagram, sơ đồ phân rã chức năng
7	CNN	Convolutional Neural Network, mạng nơ-ron tích chập
8	CSV	Comma-Separated Values, định dạng dữ liệu dạng bảng
9	DL	Deep Learning, học sâu
10	FE	Frontend, phần giao diện người dùng
11	IoU	Intersection over Union
12	JSON	JavaScript Object Notation
13	PDF	Portable Document Format
14	RGB	Hệ màu đỏ, xanh lá, xanh dương
15	SVM	Support Vector Machine
16	UI	User Interface, giao diện người dùng
17	UML	Unified Modeling Language
18	URL	Uniform Resource Locator

DANH MỤC HÌNH ẢNH

Hình 1.1 Polyb dạ dày	9
Hình 1.2 Viêm loét dạ dày.....	9
Hình 1.3: Kiến trúc và các thành phần của DeepLabv3+.....	11
Hình 1.4 Sơ đồ quy trình phân đoạn ảnh bằng Deeplabv3+	11
Hình 1.5 Quy trình hoạt động của mô hình DeepLabV3+	12
Hình 1.6: Các mặt phân cách hai classes.....	15
Hình 1.8: Margin của hai classes là bằng nhau và lớn nhất có thể.....	15
Hình 1.9: Bài toán SVM.....	16
Hình 1.10 Quy trình tổng thể khi áp dụng SVM	18
Hình 2.1. Workflow chức năng tổng quát của hệ thống GastroVision AI.	21
Hình 2.2. Workflow kiến trúc frontend - backend của hệ thống.....	26
Hình 2.3 Giao diện màn phân tích ảnh	27
Hình 2.1 Sơ đồ BFD	29
Hình 2.2 Sơ đồ use case.....	30
Hình 3.1 Phân bố số lượng ảnh theo lớp	38
Hình 3.2. Biểu đồ Train Loss và Validation Loss	39
Hình 3.3. Biểu đồ Train Accuracy và Validation Accuracy	40
Hình 3.4. Một số mẫu ảnh, mask và overlay dùng cho bài toán phân đoạn polyp.....	44
Hình 3.5 Biểu đồ Loss và Dice theo epoch	44
Hình 3.6 Kết quả train khá tốt	45
Hình 3.7 Kết quả train chưa tốt hoặc bỏ sót	45

DANH MỤC BẢNG BIỂU

Bảng 2.1 Mô tả dữ liệu đầu vào và đầu ra của hệ thống	20
Bảng 2.2. Dữ liệu đầu vào và đầu ra của hệ thống	24
Bảng 3.1 Các lớp dữ liệu trong bộ dữ liệu HyperKvasir [9]	32
Bảng 3.2 Phân tích kết quả phân loại từ ma trận nhầm lẫn	42
Bảng 3.3 Kết quả đánh giá hiệu quả phân loại của mô hình	43

MỞ ĐẦU

1. Giới thiệu đề tài

Trong quá trình học tập và tìm hiểu về lĩnh vực Trí tuệ nhân tạo, em nhận thấy các bài toán xử lý ảnh đang được ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau, đặc biệt là y tế. Việc kết hợp giữa công nghệ và chăm sóc sức khỏe không chỉ mang lại giá trị nghiên cứu mà còn có ý nghĩa thực tiễn cao khi góp phần hỗ trợ con người trong quá trình chẩn đoán và điều trị bệnh.

Bên cạnh đó, các bệnh lý liên quan đến dạ dày và đường tiêu hóa hiện nay ngày càng phổ biến do thói quen sinh hoạt, chế độ ăn uống và áp lực cuộc sống. Tại Việt Nam, tỷ lệ mắc bệnh rất cao, ước tính khoảng 15-20% dân số mắc bệnh dạ dày; chiếm tới 26-30% số người mắc bệnh đường tiêu hóa, thường gia tăng ở tại các đô thị lớn [1]. Trên thế giới, tỷ lệ mắc viêm dạ dày chiếm hơn 50% ở các nước đang phát triển và khoảng 34.7% ở các nước phát triển [2]. Nhiều người phát hiện bệnh qua các triệu chứng như đau bụng, đầy hơi, khó tiêu, buồn nôn hoặc ợ nóng, tự điều trị bệnh tại nhà hoặc chỉ đi khám khi bệnh đã kéo dài và ảnh hưởng đến sinh hoạt hằng ngày. Việc phát hiện muộn có thể làm tăng chi phí điều trị cũng như nguy cơ xuất hiện các biến chứng không mong muốn.

2. Mục tiêu đề tài

Do những khó khăn trong quá trình quan sát và đánh giá ảnh nội soi, nên em muốn phát triển đề tài xây dựng hỗ trợ phân tích nội soi đường tiêu hóa đường tiêu hóa bằng cách kết hợp mô hình học sâu Deeplabv3+ và thuật toán SVM. Hệ thống được xây dựng với mục tiêu là hỗ trợ bác sĩ trong quá trình nhận diện điểm bất thường trên ảnh nội soi, cung cấp thêm thông tin tham khảo.

Mô hình Deeplabv3+ được sử dụng để phân loại ảnh nội soi hoặc vùng tổn thương trên ảnh nội soi, xác định và khoanh vùng nghi ngờ có bất thường như polyp, các vùng niêm mạc cần được quan tâm. Thuật toán SVM được sử dụng để phân loại ảnh nội soi hoặc vùng ảnh đã được xử lý thành các nhóm nhãn tương ứng với dữ liệu huấn luyện. Kết quả sẽ giúp làm rõ vị trí, hình dạng và phạm vi của vùng tổn thương thay vì chỉ đưa

ra một kết quả chung cho toàn bộ ảnh. Kết hợp với kết quả trên, hệ thống cung cấp thông tin trực quan và có cơ sở hơn cho quá trình đánh giá.

Đề tài này cũng hướng đến sự phát triển một ứng dụng web cho phép các bác sĩ có chuyên môn tải ảnh nội soi lên hệ thống, nhận về kết quả phân loại, ảnh phân đoạn vùng tổn thương và các chỉ số đánh giá liên quan. Hệ thống không thể thay thế bác sĩ chẩn đoán được, vẫn cần phải có kinh nghiệm chuyên môn để quan sát ảnh, hỗ trợ phát hiện các vùng cần chú ý và cung cấp thêm thông tin đánh giá, phương pháp điều trị.

Trong quá trình hoàn thiện dự án, em có cơ hội được học hỏi thêm về kiến thức về bệnh dạ dày, biết quan tâm chăm sóc sức khỏe cá nhân hơn. Đề tài cũng giúp em tiếp cận về quy trình xây dựng hệ thống trí tuệ nhận tạo, gồm: thu thập và xử lý dữ liệu, huấn luyện mô hình, đánh giá kết quả, có khả năng ứng dụng vào thực tế và phục vụ cho y tế Việt Nam.

3. Mục đích nghiên cứu

Đề tài được thực hiện với mục đích tìm hiểu và xây dựng một hướng tiếp cận hỗ trợ phân tích ảnh nội soi đường tiêu hóa bằng cách kết hợp mô hình DeepLabV3+ và thuật toán SVM trong ứng dụng trí tuệ nhân tạo vào y tế, hỗ trợ bác sĩ trong phân tích hình ảnh giúp rút ngắn thời gian đánh giá, cung cấp thêm thông tin trong quá trình chẩn đoán.

DeepLabV3+ được sử dụng để xác định và tách vùng có dấu hiệu tổn thương trên ảnh nội soi, cụ thể là xác định vùng nghi ngờ polyp trên ảnh. Nhận ảnh nội soi làm đầu vào và tạo ra mask phân đoạn ở mức pixel. Mask này cho biết vùng nào trên ảnh có khả năng là polyp, sau đó được phủ màu lên ảnh gốc để tạo ảnh overlay. Vì vậy, kết quả không chỉ dừng lại ở việc thông báo ảnh có polyp hay không, mà còn chỉ ra vị trí vùng nghi ngờ trên ảnh nội soi.

Sau khi xác định được vùng quan tâm, các đặc trưng từ vùng ảnh này sẽ được sử dụng làm đầu vào cho thuật toán SVM. Các đặc trưng ảnh được trích xuất từ mô hình học sâu như ResNet50, sau đó đưa vào Linear SVM để phân loại ảnh nội soi theo các nhóm bệnh lý như bình thường, viêm thực quản và polyp. Ứng dụng SVM giúp đánh

giá khả năng kết hợp giữa đặc trưng học sâu và thuật toán học máy truyền thống trong bài toán phân loại ảnh y tế.

Mục đích của đề tài này là xây dựng một quy trình từ xử lý dữ liệu, huấn luyện mô hình, đánh giá kết quả, tích hợp vào website. Hệ thống chỉ mang tính chất hỗ trợ nghiên cứu và minh họa khả năng ứng dụng AI trong phân tích ảnh nội soi, không thay thế chẩn đoán của bác sĩ chuyên khoa.

4. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là ảnh nội soi thuộc hệ tiêu hóa, trong đó tập trung vào các ảnh có xuất hiện vùng nghi ngờ tổn thương như polyp hoặc các bất thường trên bề mặt niêm mạc. Ảnh nội soi được sử dụng làm dữ liệu đầu vào để mô hình học được đặc điểm của vùng tổn thương và phân biệt với các khu vực nền xung quanh.

Bên cạnh dữ liệu ảnh, đề tài nghiên cứu việc áp dụng mô hình DeepLabV3+ vào bài toán phân đoạn ảnh nội soi. Mô hình có nhiệm vụ xác định vị trí và phạm vi của vùng tổn thương trên ảnh, sau đó tạo ra ảnh mask thể hiện khu vực được dự đoán là bất thường.

Sau bước phân đoạn, đề tài tiếp tục nghiên cứu sử dụng thuật toán SVM để hỗ trợ xử lý kết quả từ mô hình. Các đặc trưng được trích xuất từ ảnh hoặc từ vùng tổn thương sau khi phân đoạn sẽ được đưa vào SVM nhằm hỗ trợ phân loại ảnh theo nhóm có tổn thương hoặc không có tổn thương.

Ngoài ra, đề tài cũng nghiên cứu quy trình chuẩn bị dữ liệu, xử lý ảnh, huấn luyện mô hình, đánh giá kết quả phân đoạn và kiểm tra khả năng hoạt động của hệ thống thông qua ứng dụng web minh họa. Hệ thống được xây dựng với mục đích hỗ trợ nghiên cứu và trực quan hóa kết quả, không dùng để thay thế kết luận chuyên môn của bác sĩ.

5. Phạm vi nghiên cứu

5.1 Phạm vi về dữ liệu

Đề tài sử dụng dữ liệu ảnh nội soi thuộc nhóm bệnh lý của hệ tiêu hóa. Trong đó, hướng nghiên cứu chính là các ảnh nội soi dạ dày. Tuy nhiên, do nguồn dữ liệu nội soi dạ dày có gắn nhãn phân đoạn công khai hiện nay còn khá ít, đề tài sử dụng thêm ảnh

nội soi đại trực tràng có xuất hiện polyp để phục vụ cho quá trình xây dựng và đánh giá mô hình.

Việc sử dụng dữ liệu polyp đại trực tràng nhằm khắc phục hạn chế về số lượng dữ liệu dạ dày có thể tiếp cận. Trên thực tế, dữ liệu nội soi tại bệnh viện thường liên quan đến thông tin người bệnh, vì vậy việc khai thác cần tuân thủ quy định bảo mật và quy trình phê duyệt riêng. Trong khi đó, các bộ dữ liệu như Kvasir-Seg và ETIS-LaribPolypDB đã được công bố và được sử dụng khá phổ biến trong các nghiên cứu về phân đoạn ảnh nội soi. Những bộ dữ liệu này có sẵn ảnh nội soi đi kèm ảnh nhãn, phù hợp với yêu cầu huấn luyện bài toán xác định vùng tổn thương.

Dù ảnh nội soi dạ dày và ảnh nội soi đại trực tràng được thu nhận ở các vị trí khác nhau, chúng vẫn có một số đặc điểm tương tự như bề mặt niêm mạc, vùng tổn thương nổi bật so với vùng xung quanh, hiện tượng phản sáng hoặc nhiễu ảnh trong quá trình nội soi. Vì vậy, dữ liệu polyp đại trực tràng được dùng để hỗ trợ mô hình học cách nhận biết khu vực bất thường trên ảnh nội soi. Kết quả từ quá trình này có thể là nền tảng để tiếp tục tinh chỉnh và áp dụng mô hình trên dữ liệu nội soi dạ dày thực tế sau này.

Dữ liệu đầu vào của đề tài bao gồm ảnh nội soi màu ở định dạng RGB và ảnh mask tương ứng. Trong ảnh mask, vùng có tổn thương được biểu diễn bằng giá trị 1, còn vùng không thuộc tổn thương được biểu diễn bằng giá trị 0. Toàn bộ dữ liệu được phân chia thành các tập huấn luyện, kiểm tra và đánh giá để theo dõi khả năng học của mô hình cũng như kiểm tra mức độ phù hợp của mô hình trên các ảnh chưa được sử dụng trong quá trình huấn luyện.

Đề tài chỉ tập trung xử lý ảnh nội soi tĩnh. Các dữ liệu liên quan đến hồ sơ bệnh án, thông tin nhận diện người bệnh hoặc video nội soi theo thời gian thực không nằm trong phạm vi thực hiện của đề án.

5.2 Phạm vi về công nghệ

Đề tài được xây dựng chủ yếu bằng ngôn ngữ lập trình Python. Đây là ngôn ngữ phù hợp với các bài toán liên quan đến trí tuệ nhân tạo và xử lý ảnh do có nhiều thư viện hỗ trợ, dễ triển khai và thuận tiện trong quá trình thử nghiệm mô hình.

Mô hình phân đoạn được phát triển trên framework PyTorch với kiến trúc DeepLabV3+. Thư viện segmentation-models-pytorch được sử dụng để hỗ trợ xây dựng mô hình, lựa chọn backbone và thực hiện quá trình huấn luyện. Bên cạnh đó, các thư viện như OpenCV, NumPy và Albumentations được dùng để xử lý dữ liệu ảnh trước khi đưa vào mô hình, bao gồm đọc ảnh, thay đổi kích thước, chuẩn hóa dữ liệu và tăng cường dữ liệu.

Quá trình huấn luyện được thực hiện trên nền tảng Google Colab. Google Colab cung cấp môi trường chạy Python trực tuyến và hỗ trợ sử dụng GPU, giúp giảm thời gian huấn luyện so với khi chỉ sử dụng CPU trên máy tính cá nhân. Dữ liệu huấn luyện, file trọng số mô hình và các kết quả trong quá trình thực hiện được lưu trữ trên Google Drive để thuận tiện cho việc quản lý và sử dụng lại khi cần thiết. Do tài nguyên GPU trên Google Colab được cấp phát theo từng phiên làm việc, loại GPU sử dụng có thể thay đổi tùy vào thời điểm chạy chương trình.

Ngoài phần huấn luyện mô hình, đề tài xây dựng một ứng dụng web đơn giản nhằm minh họa cách sử dụng hệ thống. Backend có nhiệm vụ tiếp nhận ảnh nội soi từ người dùng, đưa ảnh vào mô hình đã huấn luyện và trả về kết quả dự đoán vùng tổn thương. Phần giao diện được xây dựng bằng HTML, CSS và JavaScript, hỗ trợ người dùng tải ảnh lên và xem kết quả phân đoạn trực quan.

Phạm vi công nghệ của đề tài tập trung vào việc xử lý ảnh nội soi tĩnh, huấn luyện mô hình DeepLabV3+ và xây dựng giao diện minh họa trên nền tảng web. Hệ thống chưa được triển khai trực tiếp tại bệnh viện, chưa kết nối với thiết bị nội soi thực tế và chưa xử lý dữ liệu video nội soi theo thời gian thực.

6. Phương pháp nghiên cứu

Để thực hiện đề tài, em đã sử dụng phương pháp nghiên cứu tài liệu kết hợp với phương pháp thực nghiệm. Trước hết, tìm hiểu các tài liệu, bài báo và nghiên cứu liên quan đến xử lý ảnh y tế, ảnh nội soi, bài toán phân đoạn ảnh và các mô hình học sâu đang được sử dụng trong lĩnh vực này. Qua quá trình tìm hiểu, em lựa chọn DeepLabV3+ làm mô hình chính để xác định vùng tổn thương trên ảnh nội soi và sử dụng thuật toán SVM nhằm hỗ trợ phân loại kết quả sau xử lý.

Dữ liệu được sử dụng là các bộ dữ liệu ảnh nội soi công khai có kèm theo ảnh mask, được kiểm tra, sắp xếp và xử lý trước khi đưa vào huấn luyện. Một số bước xử lý được thực hiện gồm thay đổi kích thước ảnh, chuẩn hóa dữ liệu, chia dữ liệu thành các tập huấn luyện, kiểm tra và đánh giá. Ngoài ra, một số kỹ thuật tăng cường dữ liệu cũng được áp dụng nhằm làm đa dạng dữ liệu đầu vào và hạn chế tình trạng mô hình học quá sát trên tập huấn luyện.

Sau khi dữ liệu được chuẩn bị, mô hình DeepLabV3+ được huấn luyện để dự đoán vùng tổn thương trên ảnh nội soi. Kết quả đầu ra của mô hình là ảnh mask, trong đó thể hiện khu vực mà mô hình nhận định có dấu hiệu bất thường. Kết quả phân đoạn được đánh giá thông qua các chỉ số như IoU, Dice Score, Precision và Recall để xem mức độ trùng khớp giữa vùng dự đoán và vùng nhãn thực tế.

Vùng ảnh được xác định sau bước phân đoạn được sử dụng để trích xuất thông tin phục vụ cho thuật toán SVM. SVM được áp dụng nhằm hỗ trợ phân loại ảnh theo hai nhóm: ảnh có tổn thương và ảnh không có tổn thương. Kết quả của bước này giúp hệ thống không chỉ đánh dấu vị trí nghi ngờ mà còn đưa ra nhận định tổng quát hơn đối với ảnh đầu vào.

Các quá trình huấn luyện và thử nghiệm được thực hiện trên môi trường Google Colab có hỗ trợ GPU. Trong quá trình thực hiện, nhóm thay đổi và so sánh một số tham số như kích thước ảnh đầu vào, số epoch, batch size và tốc độ học để lựa chọn cấu hình phù hợp hơn cho mô hình.

Mô hình sau khi huấn luyện được tích hợp vào ứng dụng web minh họa. Người dùng có thể tải ảnh nội soi lên hệ thống, sau đó hệ thống thực hiện dự đoán, hiển thị vùng tổn thương được đánh dấu và trả về kết quả phân loại tương ứng. Thông qua quá trình này, nhóm đánh giá khả năng áp dụng mô hình vào một hệ thống hỗ trợ quan sát ảnh nội soi ở mức cơ bản.

7. Ý nghĩa thực tiễn của đề tài

Trong thực tế, việc quan sát và đánh giá ảnh nội soi thường phụ thuộc nhiều vào kinh nghiệm của bác sĩ. Tuy nhiên, ảnh nội soi có thể xuất hiện các yếu tố như ánh sáng phản chiếu, vùng niêm mạc không đồng đều hoặc chất lượng ảnh chưa tốt, khiến việc

nhận biết vùng bất thường trở nên khó khăn hơn. Vì vậy, việc nghiên cứu các phương pháp hỗ trợ phân tích ảnh nội soi bằng trí tuệ nhân tạo có ý nghĩa nhất định trong quá trình hỗ trợ quan sát và đánh giá hình ảnh.

Đề tài ứng dụng mô hình DeepLabV3+ để xác định vị trí vùng nghi ngờ tổn thương trên ảnh nội soi. Kết quả phân đoạn giúp làm nổi bật khu vực mà mô hình dự đoán là bất thường, từ đó hỗ trợ người dùng tập trung quan sát vào vùng cần chú ý thay vì phải xem toàn bộ ảnh một cách thủ công.

Bên cạnh đó, việc kết hợp thuật toán SVM giúp hệ thống có thêm khả năng đưa ra kết quả phân loại cơ bản giữa ảnh có tổn thương và ảnh không có tổn thương. Sự kết hợp này giúp kết quả đầu ra trực quan hơn, vì người dùng vừa có thể xem vị trí vùng bất thường trên ảnh, vừa có thêm thông tin phân loại do hệ thống dự đoán.

Về mặt học thuật, đề tài giúp sinh viên tiếp cận quy trình xây dựng một hệ thống xử lý ảnh y tế, từ bước chuẩn bị dữ liệu, huấn luyện mô hình, đánh giá kết quả đến xây dựng ứng dụng minh họa. Đây cũng là nền tảng để có thể tiếp tục nghiên cứu các hướng phát triển khác trong tương lai, chẳng hạn như sử dụng dữ liệu nội soi dạ dày thực tế, phân loại nhiều nhóm tổn thương hoặc xử lý video nội soi.

Việc lưu trữ thông tin bệnh nhân cùng với kết quả phân tích và kết luận của bác sĩ giúp quá trình quản lý hồ sơ trở nên thuận tiện hơn, đồng thời hỗ trợ việc theo dõi và so sánh kết quả giữa các lần nội soi. Nếu tiếp tục được hoàn thiện với nguồn dữ liệu đa dạng hơn và được kiểm chứng trong môi trường lâm sàng, hệ thống có thể trở thành công cụ hỗ trợ hữu ích trong hoạt động khám chữa bệnh cũng như phục vụ công tác đào tạo và nghiên cứu trong lĩnh vực y tế.

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

1.1 Tổng quan về bệnh dạ dày

Theo số liệu GLOBOCAN năm 2022, trên thế giới có khoảng 968.784 ca ung thư dạ dày mới được ghi nhận và khoảng 660.175 trường hợp tử vong. Ung thư dạ dày nằm trong nhóm năm loại ung thư có số ca mắc và số ca tử vong cao trên toàn cầu. Điều này cho thấy các bệnh lý liên quan đến dạ dày vẫn là vấn đề cần được quan tâm trong lĩnh vực chăm sóc sức khỏe.[3]

Tại Việt Nam, bệnh lý dạ dày cũng là vấn đề đáng quan tâm, đặc biệt là ung thư dạ dày. GLOBOCAN 2022 ghi nhận Việt Nam có khoảng 16.277 ca ung thư dạ dày mới trong năm, chiếm khoảng 9% tổng số ca ung thư mới. Ung thư dạ dày đứng thứ năm về số ca mắc mới và đứng thứ ba về số ca tử vong do ung thư ở cả hai giới. Những con số này cho thấy việc phát hiện sớm các bất thường ở dạ dày có ý nghĩa quan trọng.[4]


Dạ dày là cơ quan thuộc hệ tiêu hóa, nằm giữa thực quản và tá tràng. Cơ quan này có chức năng tiếp nhận thức ăn, co bóp để nghiền nhỏ thức ăn và tiết dịch vị hỗ trợ quá trình tiêu hóa. Bề mặt phía trong dạ dày được bao phủ bởi lớp niêm mạc. Khi lớp niêm mạc này bị tổn thương, viêm hoặc xuất hiện các vùng phát triển bất thường, người bệnh có thể gặp nhiều bệnh lý khác nhau tại dạ dày.

Viêm dạ dày là tình trạng niêm mạc dạ dày bị tổn thương dẫn đến viêm. Loét dạ dày- tá tràng là khi xuất hiện vết loét trên lớp niêm mạc dạ dày hoặc tá tràng. Nguyên nhân phổ biến do sử dụng thuốc kháng viêm không steroid trong thời gian dài, uống rượu bia hoặc các kích thích khác cũng có thể làm tổn thương niêm mạc dạ dày.

Polyp dạ dày là tổn thương phát triển bất thường từ niêm mạc dạ dày, thường được phát hiện trong quá trình nội soi. Hình dạng, kích thước và nguy cơ của polyp không giống nhau giữa các trường hợp. Phần lớn polyp không phải là tổn thương ác tính, tuy nhiên một số loại có nguy cơ tiến triển thành ung thư hoặc đã mang đặc điểm ác tính. Vì vậy, hình ảnh nội soi chỉ giúp nhận biết tổn thương ban đầu; việc xác định chính xác bản chất polyp cần dựa vào đánh giá mô bệnh học từ mẫu sinh thiết hoặc mẫu tổn thương được cắt bỏ. [5]



Hình 1.1 Polyb dạ dày



Hình 1.2 Viêm loét dạ dày

Ung thư dạ dày là bệnh lý ác tính xuất phát từ các tế bào của thành dạ dày. Ở giai đoạn mới phát hiện, triệu chứng thường không biểu hiện rõ, có thể giống với các rối loạn tiêu hóa thông thường như đau bụng, khó tiêu hoặc nhanh no. Khi khám kiểm soát, bác sĩ cần kết hợp triệu chứng lâm sàng, kết quả nội soi và xét nghiệm mô bệnh học để xác định bệnh. Nội soi đường tiêu hóa kèm sinh thiết là một trong những phương pháp quan trọng để phát hiện vùng bất thường và kiểm tra tế bào dưới kính hiển vi. [6]

Nội soi tiêu hóa là kỹ thuật sử dụng một ống mềm có gắn camera để quan sát bề mặt bên trong của thực quản, dạ dày và tá tràng. Trong quá trình nội soi, bác sĩ có thể quan sát các vùng viêm, trợt, loét, polyp, chảy máu hoặc những khu vực có hình thái bất thường. Tùy vào tình trạng thực tế, bác sĩ có thể lấy mẫu mô, xử lý chảy máu hoặc thực hiện một số thủ thuật khác thông qua ống nội soi. [7]

Điều trị bệnh lý dạ dày không áp dụng chung một phương pháp cho tất cả trường hợp. Bác sĩ thường dựa vào nguyên nhân gây bệnh, mức độ tổn thương, kết quả nội soi, xét nghiệm vi khuẩn *H. pylori* và tình trạng sức khỏe của người bệnh để lựa chọn hướng điều trị phù hợp. Vì vậy, người bệnh không nên tự mua thuốc hoặc tự dùng kháng sinh khi chưa được thăm khám.

Khi người bệnh nhiễm *H. pylori*, bác sĩ thường chỉ định phác đồ diệt trừ vi khuẩn, kết hợp kháng sinh và thuốc giảm tiết acid. Người bệnh cần dùng thuốc đúng liều, đủ thời gian để hạn chế nguy cơ điều trị thất bại hoặc kháng thuốc. Đối với loét dạ dày - tá tràng, điều trị tập trung vào làm lành ổ loét và loại bỏ nguyên nhân như *H. pylori* hoặc

thuốc kháng viêm. Trường hợp có biến chứng như xuất huyết tiêu hóa, người bệnh có thể cần nhập viện, nội soi cầm máu hoặc can thiệp phẫu thuật. Với polyp dạ dày, hướng xử lý phụ thuộc vào kích thước, hình dạng, vị trí và kết quả sinh thiết. Một số polyp nhỏ có thể được theo dõi định kỳ, trong khi polyp lớn, chảy máu hoặc có nguy cơ bất thường có thể được cắt bỏ qua nội soi. Đối với ung thư dạ dày, phương pháp điều trị phụ thuộc vào giai đoạn bệnh. Nếu phát hiện sớm, một số trường hợp có thể xử lý bằng nội soi. Ở giai đoạn tiến triển hơn, người bệnh có thể cần phẫu thuật, hóa trị, xạ trị hoặc các phương pháp điều trị chuyên sâu khác.

Bên cạnh điều trị y khoa, người bệnh nên duy trì chế độ sinh hoạt phù hợp như ăn uống đúng bữa, hạn chế rượu bia, không hút thuốc và không tự ý dùng thuốc kháng viêm kéo dài khi chưa có chỉ định của bác sĩ.

1.2. Mô hình phân đoạn hình ảnh DeepLabv3+


1.2.1. Giới thiệu DeepLabv3+

DeepLabv3+ là một mô hình học sâu được dùng phổ biến trong bài toán phân đoạn ảnh ngữ nghĩa. Khác với bài toán phân loại chỉ cần cho biết ảnh thuộc lớp nào, phân đoạn ảnh yêu cầu mô hình gán nhãn cho từng điểm ảnh. Vì vậy, mô hình không chỉ nhận biết đối tượng xuất hiện trong ảnh, mà còn xác định được vị trí của đối tượng.

DeepLabv3+ được phát triển từ các phiên bản DeepLab trước đó. Điểm cải tiến quan trọng của mô hình này là kết hợp giữa phần mã hóa đặc trưng và phần giải mã. Nhờ có bộ giải mã, kết quả phân đoạn có thể giữ được thông tin biên và hình dạng đối tượng tốt hơn. Trong đề án này, DeepLabv3+ được sử dụng để phân đoạn vùng polyp trên ảnh nội soi, giúp hệ thống hiển thị vùng nghi ngờ bằng mặt nạ hoặc ảnh overlay.

1.2.2. Kiến trúc mô hình DeepLabv3+

Về mặt kiến trúc và các thành phần trong DeepLabv3+ bao gồm ba phần chính: backbone, module ASPP và decoder.



Hình 1.3: Kiến trúc và các thành phần của DeepLabv3+ [8]

Backbone là mạng nền dùng để trích xuất đặc trưng từ ảnh đầu vào. Các lớp đầu của backbone thường học những đặc trưng đơn giản như cạnh, màu sắc và cấu trúc bề 17 mặt. Các lớp sau học những đặc trưng có mức ngữ nghĩa cao hơn, giúp mô hình hiểu được đối tượng cần phân đoạn. [8]

Khối ASPP, viết tắt của Atrous Spatial Pyramid Pooling, là thành phần giúp mô hình quan sát ảnh ở nhiều tỉ lệ khác nhau. Thay vì chỉ dùng một kích thước trường nhìn, ASPP sử dụng nhiều phép tích chập có độ giãn khác nhau. Nhờ đó, mô hình có thể nắm bắt cả chi tiết nhỏ và ngữ cảnh rộng trong ảnh. [8]


Decoder có nhiệm vụ khôi phục lại thông tin không gian đã bị giảm trong quá trình trích xuất đặc trưng. Phần này kết hợp đặc trưng mức cao từ encoder với đặc trưng mức thấp từ các lớp gần đầu vào. Sự kết hợp này giúp kết quả phân đoạn có biên rõ hơn, đặc biệt quan trọng với ảnh y tế vì vùng tổn thương có thể nhỏ và khó phân biệt. [8]

Sơ đồ quy trình phân đoạn ảnh bằng DeepLabV3+



Hình 1.4 Sơ đồ quy trình phân đoạn ảnh bằng Deeplabv3+

1.2.3. Nguyên lý hoạt động



Hình 1.5 Quy trình hoạt động của mô hình DeepLabV3+

DeepLabV3+ xử lý ảnh theo kiến trúc encoder–decoder. Ảnh đầu vào được đưa qua backbone để trích xuất đặc trưng ở nhiều mức. Các tầng nông tạo ra đặc trưng mức thấp, chứa thông tin về vị trí, đường biên và kết cấu; trong khi các tầng sâu tạo ra đặc trưng mức cao, thể hiện thông tin ngữ nghĩa của đối tượng.

Đặc trưng mức cao được đưa vào mô-đun ASPP. Mô-đun này sử dụng các lớp Atrous Convolution với nhiều hệ số giãn nở khác nhau để thu thập ngữ cảnh ở nhiều tỷ lệ, đồng thời duy trì thông tin không gian của ảnh.

Ở giai đoạn decoder, đặc trưng từ ASPP được lấy mẫu lên và kết hợp với đặc trưng mức thấp từ backbone. Trước khi kết hợp, đặc trưng mức thấp được giảm số kênh bằng tích chập 1×1 . Sau đó, các đặc trưng được ghép nối và tiếp tục xử lý qua các lớp tích chập để làm rõ đường biên đối tượng.

Cuối cùng, đặc trưng được lấy mẫu lên về kích thước gần với ảnh đầu vào. Lớp đầu ra tạo bản đồ xác suất cho từng điểm ảnh, từ đó sinh ra mặt nạ phân đoạn thể hiện vùng thuộc đối tượng và vùng nền.

1.2.4. Ưu điểm và nhược điểm của DeepLabv3+

DeepLabv3+ có ưu điểm lớn là phân đoạn được đối tượng với ranh giới khá rõ nhờ kết hợp ASPP và decoder - vừa lấy được ngữ cảnh tổng quát, vừa giữ thông tin vị trí. Điều này phù hợp với bài toán phân đoạn polyp, vì vùng polyp có kích thước đa dạng và ranh giới không phải lúc nào cũng rõ. Mô hình cũng linh hoạt khi có thể kết hợp nhiều loại backbone, giúp em dễ dàng thử nghiệm và lựa chọn backbone phù hợp với phần cứng.

Tuy nhiên, mô hình cũng có hạn chế. Quá trình huấn luyện cần tài nguyên tính toán lớn, đặc biệt với ảnh kích thước cao hoặc backbone phức tạp. Để khắc phục, em sử dụng ảnh đầu vào kích thước 352x352 và áp dụng chiến lược hai giai đoạn (warm-up và fine-tune) trên Google Colab. Ngoài ra, với vùng tổn thương quá nhỏ, bị che khuất hoặc có ranh giới mờ, kết quả phân đoạn có thể chưa thật sự chính xác - đây cũng là hạn chế mà bất kỳ mô hình phân đoạn nào cũng gặp phải.

1.3. Thuật toán học máy Support Vector Machine

Ngoài phân đoạn, đề án còn giải quyết bài toán phân loại đặc trưng vùng polyp. Sau khi mô hình phân đoạn tạo mặt nạ, các đặc trưng như diện tích, chu vi, hình dạng và kết cấu được trích xuất và đưa vào bộ phân loại. Sau đó sử dụng Support Vector Machine (SVM) vì đây là thuật toán có nền tảng toán học vững, hoạt động ổn định với dữ liệu có số chiều lớn - đặc điểm thường gặp của vector đặc trưng ảnh y tế.

Support Vector Machine (SVM) là thuật toán học có giám sát dùng cho bài toán phân loại. Ý tưởng chính là tìm mặt phân cách tốt nhất để tách các mẫu dữ liệu thuộc những lớp khác nhau. Với bài toán hai lớp, SVM tìm siêu phẳng sao cho khoảng cách (margin) từ siêu phẳng đến các điểm gần nhất của mỗi lớp là lớn nhất. Các điểm nằm gần mặt phân cách nhất và ảnh hưởng trực tiếp đến việc xác định siêu phẳng được gọi là support vectors - chính là những mẫu "khó" nhất trong tập huấn luyện.

Trong thực tế, dữ liệu không phải lúc nào cũng tách được hoàn toàn. SVM sử dụng soft-margin để cho phép một số mẫu bị phân loại sai, đổi lại mô hình tổng quát tốt hơn trên dữ liệu mới. Trong bài toán phân loại đặc trưng polyp, điều này rất cần thiết vì các đặc trưng giữa polyp lành tính và ác tính có thể chồng lấn lên nhau.

1.3.1 Biểu diễn dữ liệu và nhãn

Trong học có giám sát nói chung và phân loại nhị phân nói riêng, dữ liệu và nhãn được thể hiện dưới dạng các cặp (input, output). Cụ thể:


- Dữ liệu (Predictors / Features): Được biểu diễn dưới dạng một vector hoặc một tập hợp các biến đặc trưng (feature variables). Không gian được định nghĩa bởi tất cả các giá trị khả dĩ của các đặc trưng này được gọi là không gian đặc trưng (feature space). Mỗi hàng trong bảng dữ liệu (một quan sát) là một điểm trong không gian này.
- Nhãn (Labels / Targets): Là giá trị đầu ra tương ứng với dữ liệu đầu vào. Trong phân loại nhị phân, nhãn thường được mã hóa bằng số nhị phân (ví dụ: 1 cho lớp tích cực, 0 cho lớp tiêu cực).

Tập dữ liệu thường được chia làm hai phần:

- Tập có nhãn (Labeled data): Dùng để huấn luyện mô hình. Thuật toán sẽ học mối quan hệ giữa các đặc trưng và nhãn này.
- Tập chưa có nhãn (Unlabeled data): Dùng để kiểm tra hoặc dự đoán. Sau khi học xong, mô hình sẽ được áp dụng lên tập này để gán nhãn cho chúng.
- Decision Boundary (Ranh giới quyết định): Đây là một thuật ngữ tổng quát hơn, có thể được dùng để chỉ siêu phẳng trong bối cảnh của SVM

1.3.2. Nguyên lý của SVM

Giả sử rằng có hai class khác nhau được mô tả bởi các điểm trong không gian nhiều chiều, hai classes này linearly separable, tức tồn tại một siêu phẳng phân chia chính xác hai classes đó. Hãy tìm một siêu mặt phẳng phân chia hai classes đó, tức tất cả các điểm thuộc một class nằm về cùng một phía của siêu mặt phẳng đó và ngược phía với toàn bộ các điểm thuộc class còn lại. Thuật toán Perceptron Learning Algorithm có thể làm được việc này nhưng nó có thể cho vô số nghiệm như hình 2.6 dưới đây:



Hình 1.6: Các mặt phân cách hai classes

Vấn đề đặt ra là: trong không gian các siêu phẳng phân tách khả dĩ, làm thế nào để xác định được siêu phẳng tối ưu theo một tiêu chí định lượng cụ thể. Cần một phương pháp lựa chọn siêu phẳng sao cho tối đa hóa khoảng cách biên tối thiểu giữa hai lớp, từ đó đảm bảo tính cân bằng và khả năng tổng quát hóa tốt hơn cho mô hình phân loại.

1.3.3 Vector đặc trưng (Feature Vector)


Mỗi điểm dữ liệu được biểu diễn dưới dạng vector đặc trưng là vector p-chiều:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})$$

Kèm theo nhãn lớp $y_i \in \{1, -1\}$ để chỉ lớp dương hoặc lớp âm. Tập dữ liệu gồm n cặp: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$.

Trong bài toán phân loại bệnh dạ dày (GastroVision), mỗi ảnh sau khi trích xuất đặc trưng sẽ được biểu diễn thành 1 vector, ví dụ: màu sắc, hình dạng, kết cấu.

1.3.4 Ý tưởng lề cực đại (Maximum Margin)




Hình 1.7: Margin của hai classes là bằng nhau và lớn nhất có thể

Xét bài toán phân lớp nhị phân tuyến tính, giả sử ta đo “mức độ tối ưu” của một siêu phẳng phân tách thông qua khoảng cách tối thiểu từ các điểm dữ liệu của mỗi lớp đến siêu phẳng đó. Trong trường hợp ở hình 1 (bên trái), siêu phẳng phân chia nằm gần các điểm của lớp hình tròn đỏ hơn so với lớp hình vuông xanh. Điều này dẫn đến khoảng cách biên (margin) của lớp đỏ nhỏ hơn, làm giảm độ ổn định của mô hình trước nhiễu và dữ liệu mới.

Để khắc phục vấn đề này, siêu phẳng cần được xác định sao cho khoảng cách từ nó đến các điểm gần nhất của hai lớp là như nhau. Những điểm dữ liệu nằm sát siêu phẳng nhất được gọi là support vectors, và khoảng cách từ các điểm này đến siêu phẳng được gọi là margin. Việc duy trì margin cân bằng giúp siêu phẳng không bị lệch về một phía của dữ liệu.

Tuy nhiên, chỉ đảm bảo khoảng cách hai phía bằng nhau vẫn chưa phải là điều kiện tối ưu. Một siêu phẳng có margin bằng nhau cho hai lớp nhưng giá trị margin nhỏ sẽ không đảm bảo khả năng phân tách tốt. Do đó, tiêu chí quan trọng hơn là tối đa hóa margin. Như ở Hình 2 (bên phải), giữa hai siêu phẳng thỏa mãn điều kiện cân bằng (đường nét liền màu đen và đường nét đứt màu lục), siêu phẳng có margin lớn hơn (đường nét liền) sẽ mang lại khả năng phân lớp tốt hơn do tạo ra khoảng cách phân tách rõ ràng hơn giữa hai lớp.

1.3.5. Lề cứng (Hard Margin) cho dữ liệu khả tách tuyến tính



Hình 1.8: Bài toán SVM

Giả sử rằng các cặp dữ liệu của *training set* là $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$ với vector $x_i \in \mathbb{R}^d$ thể hiện *đầu vào* của một điểm dữ liệu và y_i là *nhãn* của điểm dữ liệu đó. d là số chiều của dữ liệu và N là số điểm dữ liệu. Giả sử rằng *nhãn* của mỗi điểm dữ liệu được xác định bởi $y_i = 1$ (class 1) hoặc $y_i = -1$ (class 2).

Giả sử rằng các điểm vuông xanh thuộc class 1, các điểm tròn đỏ thuộc class -1 và mặt $w^T x + b = w_1 x_1 + w_2 x_2 + b = 0$ là mặt phân chia giữa hai classes. Hơn nữa, class 1 nằm về *phía dương*, class -1 nằm về *phía âm* của mặt phân chia. Nếu ngược lại, ta chỉ cần đổi dấu của w và b . với cặp dữ liệu (x_n, y_n) bất kỳ, khoảng cách từ điểm đó tới mặt phân chia là:

$$y_n \frac{w^T x_n + b}{\|w\|^2} \quad (1)$$

Ở (1) có thể dễ nhận thấy vì theo giả sử ở trên, y_n luôn cùng dấu với *phía* của x_n . Từ đó suy ra y_n cùng dấu với $(w^T x_n + b)$, và tử số luôn là 1 số không âm.

Với mặt phân chia như trên, *margin* được tính là khoảng cách gần nhất từ 1 điểm tới mặt đó (bất kể điểm nào trong hai classes):

$$\text{margin} = \min_n \frac{y_n(w^T x_n + b)}{\|w\|^2} \quad (2)$$

Bài toán tối ưu trong SVM chính là bài toán tìm w và b sao cho *margin* này đạt giá trị lớn nhất:

$$(w, b) = \arg \max_{w, b} \left\{ \min_n \frac{y_n(w^T x_n + b)}{\|w\|_2} \right\} = \arg \max_{w, b} \left\{ \frac{1}{\|w\|_2} \min_n y_n(w^T x_n + b) \right\} \quad (3)$$

Bài toán tối ưu trên có thể đưa về bài toán tối ưu có ràng buộc sau đây:

$$(w, b) = \arg \max_{w, b} \frac{1}{\|w\|^2} \quad (4)$$

với các ràng buộc: $y_n(w^T x_n + b) \geq 1, \forall n = 1, 2, \dots, N$


Nhận thấy rằng việc tối đa hóa $\frac{1}{\|w\|^2}$ tương đương với việc tối thiểu hóa $\|w\|^2$, do đó bài toán (2) có thể được biến đổi tương đương thành:

$$(w, b) = \arg \min_{w, b} \frac{1}{2} \|w\|_2^2 \quad (5)$$

với các ràng buộc: $1 - y_n(w^T x_n + b) \leq 0, \forall n = 1, 2, \dots, N$

1.3.6 Quy trình tổng thể khi áp dụng SVM

Trích xuất vector đặc trưng được dùng để xử lý do máy tính không thể xử lý trực tiếp ảnh pixel nên mỗi ảnh nội soi được đưa qua một mạng CNN đã được huấn luyện trước (pre-trained) như ResNet hoặc VGG để trích xuất đặc trưng. Kết quả là mỗi ảnh được biểu diễn dưới dạng một vector đặc trưng có số chiều cố định, thường là 2048 chiều đối với ResNet-50.



Hình 1.9 Quy trình tổng thể khi áp dụng SVM

Huấn luyện mô hình SVM. Vì bài toán có 27 lớp (phân loại đa lớp) nên chiến lược One-vs-Rest được sử dụng, tức là huấn luyện 27 bộ phân loại SVM nhị phân, mỗi bộ tách một lớp ra khỏi phần còn lại. Trong quá trình huấn luyện, SVM xác định các support vectors (những ảnh nằm gần ranh giới giữa hai lớp nhất), sau đó học siêu phẳng phân chia có phương trình $w^T x - b = 0$ sao cho khoảng cách margin ($2/\|w\|$) giữa hai biên là lớn nhất.

Đánh giá mô hình. Mô hình được đánh giá trên tập test thông qua các độ đo như accuracy, precision, recall, F1-score và confusion matrix, từ đó xác định hiệu năng phân loại trên từng lớp nhãn nội soi.

Khi hệ thống tiếp nhận một ảnh nội soi mới, ảnh sẽ trải qua quy trình tiền xử lý giống với dữ liệu huấn luyện nhằm đảm bảo tính nhất quán. Sau đó, mô hình CNN đã

được huấn luyện trước sẽ trích xuất đặc trưng và biểu diễn ảnh dưới dạng một vector có số chiều cố định.

Vector đặc trưng này lần lượt được đưa vào tất cả các bộ phân loại SVM đã xây dựng theo chiến lược One-vs-Rest. Mỗi bộ phân loại sẽ tính giá trị của hàm quyết định để đánh giá mức độ phù hợp của ảnh với lớp mà nó phụ trách. Sau khi thu được kết quả từ tất cả các mô hình, hệ thống lựa chọn lớp có điểm quyết định cao nhất làm kết quả phân loại cuối cùng.

1.3.7 Ưu điểm và nhược điểm

Ưu điểm:

Việc trích xuất vector đặc trưng giúp chuyển đổi ảnh nội soi từ dữ liệu pixel có kích thước lớn thành dạng biểu diễn số có số chiều cố định, tạo điều kiện thuận lợi cho quá trình huấn luyện và phân loại dữ liệu. Khi sử dụng các mô hình CNN đã được huấn luyện trước như ResNet hoặc VGG, hệ thống có thể tận dụng những đặc trưng đã được học từ tập dữ liệu quy mô lớn để nhận diện các đặc điểm quan trọng của ảnh, chẳng hạn như hình dạng, kết cấu và sự phân bố màu sắc. Nhờ đó, mô hình không chỉ giảm được khối lượng dữ liệu cần xử lý mà còn cải thiện hiệu quả tính toán và duy trì độ chính xác ngay cả khi tập dữ liệu nội soi không quá lớn.

Nhược điểm:

Mặc dù mang lại nhiều lợi ích, phương pháp này vẫn tồn tại một số hạn chế. Hiệu quả của vector đặc trưng phụ thuộc đáng kể vào kiến trúc mạng CNN được sử dụng; nếu mô hình không phù hợp với đặc điểm của dữ liệu nội soi thì khả năng biểu diễn đặc trưng sẽ bị ảnh hưởng. Bên cạnh đó, quá trình trích xuất có thể làm mất một phần thông tin chi tiết của ảnh, đặc biệt là những đặc điểm nhỏ có ý nghĩa trong chẩn đoán. Việc sử dụng các mô hình sâu như ResNet-50 hoặc VGG cũng yêu cầu tài nguyên tính toán tương đối cao trong giai đoạn trích xuất đặc trưng, đồng thời các vector thu được có tính trừu tượng nên khó giải thích trực tiếp ý nghĩa của từng thành phần.

CHƯƠNG 2: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

2.1 Mô tả bài toán

Đề tài xây dựng một website hỗ trợ đọc ảnh nội soi tiêu hóa. Người dùng nhập thông tin bệnh nhân, tải ảnh nội soi lên hệ thống, sau đó hệ thống trả về nhóm kết quả chính gồm: bình thường, viêm/bất thường niêm mạc hoặc polyp.

Nếu ảnh được nhận diện có polyp, mô hình DeepLabV3+ sẽ khoanh vùng nghi ngờ và tạo mask phân đoạn để bác sĩ dễ quan sát hơn. Ngoài kết quả chính, hệ thống còn hiển thị một số nhãn phụ từ mô hình để hỗ trợ phân mô tả nội soi và xuất báo cáo.

Sau khi xem kết quả, bác sĩ có thể chỉnh sửa nhận xét, nhập kết luận cuối cùng, lưu hồ sơ và xuất file PDF cho bệnh nhân. Hệ thống chỉ hỗ trợ tham khảo, kết luận cuối cùng vẫn do bác sĩ quyết định.

Bảng 2.1 Mô tả dữ liệu đầu vào và đầu ra của hệ thống

Input	Output
Thông tin bệnh nhân: Họ tên, tuổi, giới tính, mã bệnh nhân (nếu có) và các thông tin cần thiết phục vụ việc lưu trữ hồ sơ khám. Ảnh nội soi tiêu hóa: Ảnh do bác sĩ hoặc nhân viên y tế tải lên hệ thống, là dữ liệu đầu vào để mô hình AI thực hiện phân tích và nhận diện tổn thương.	Kết quả phân loại ảnh nội soi: Hệ thống xác định ảnh thuộc một trong ba lớp gồm Normal (Bình thường), Esophagitis (Viêm/Bất thường niêm mạc) hoặc Polyps (Polyp). Kết quả phân đoạn (đối với lớp Polyps): Nếu ảnh được phân loại là Polyps, hệ thống sử dụng mô hình DeepLabV3+ để tạo mask phân đoạn và khoanh vùng vị trí nghi ngờ có polyp trên ảnh nội soi. Các nhãn phụ (Secondary labels): Hiển thị thêm các nhãn mô tả đặc điểm hình ảnh nhằm hỗ trợ bác sĩ trong quá trình đọc và ghi nhận kết quả nội soi.

	Nhận xét và kết luận: Bác sĩ có thể xem kết quả dự đoán của hệ thống, chỉnh sửa nhận xét và nhập kết luận cuối cùng trước khi lưu hồ sơ. Báo cáo kết quả: Hệ thống lưu thông tin khám và cho phép xuất báo cáo dưới định dạng PDF để lưu trữ hoặc cung cấp cho bệnh nhân.
--	---

2.2. Yêu cầu chức năng

Hệ thống cần xử lý được một quy trình tương đối giống thao tác thực tế: có hồ sơ bệnh nhân, có ảnh nội soi, có kết quả hình ảnh, có phần bác sĩ kiểm tra lại và có báo cáo PDF sau cùng. Vì vậy, yêu cầu hệ thống không chỉ dừng ở việc mô hình dự đoán đúng nhãn ảnh, mà còn phải trình bày kết quả theo cách dễ hiểu và phù hợp với báo cáo bệnh án.



Hình 2.1. Workflow chức năng tổng quát của hệ thống GastroVision AI.

Các yêu cầu chức năng chính gồm:

- Nhập thông tin bệnh nhân như họ tên, tuổi, giới tính, triệu chứng, tiền sử bệnh và kết quả dạ dày trước đó nếu có.
- Tải ảnh nội soi lên hệ thống, xem ảnh trước khi phân tích và kiểm tra ảnh hợp lệ.

- Phân loại ảnh nội soi về ba nhóm chính: bình thường, viêm/bất thường niêm mạc và polyp.
- Hiện thị xác suất của từng nhóm chính để người dùng biết mức độ tin cậy của kết quả.
- Hiện thị thêm các nhãn phụ từ mô hình để hỗ trợ phần mô tả chuyên sâu trong báo cáo.
- Khi ảnh thuộc nhóm polyp, hệ thống chạy DeepLabV3+ để tạo mask và ảnh khoanh vùng nghi ngờ.
- Cho phép bác sĩ chỉnh sửa mô tả nội soi, nhập kết luận cuối cùng, lưu hồ sơ và xuất báo cáo PDF.

2.3. Yêu cầu phi chức năng

Bên cạnh các yêu cầu chức năng, hệ thống cần đáp ứng các yêu cầu phi chức năng nhằm đảm bảo khả năng hoạt động ổn định, hiệu quả và thuận tiện cho người sử dụng.

- Hiệu năng: Hệ thống cần có khả năng xử lý và trả về kết quả dự đoán trong thời gian ngắn, hạn chế độ trễ khi người dùng tải ảnh nội soi lên.
- Độ chính xác: Mô hình phân loại cần đạt độ chính xác cao và duy trì kết quả ổn định trên các tập dữ liệu kiểm thử khác nhau.
- Khả năng mở rộng: Hệ thống cần cho phép bổ sung thêm dữ liệu huấn luyện hoặc mở rộng số lượng lớp phân loại mà không ảnh hưởng lớn đến kiến trúc hiện có.
- Độ tin cậy: Hệ thống phải hoạt động ổn định trong quá trình sử dụng, hạn chế lỗi khi xử lý ảnh không hợp lệ hoặc dữ liệu đầu vào không đúng định dạng.
- Bảo mật: Thông tin và hình ảnh do người dùng tải lên cần được bảo vệ, không bị truy cập trái phép hoặc sử dụng ngoài mục đích của hệ thống.
- Khả năng sử dụng: Hệ thống cần có thao tác đơn giản, dễ sử dụng, giúp người dùng có thể tải ảnh và xem kết quả dự đoán một cách thuận tiện.

2.4. Yêu cầu về giao diện

Giao diện của hệ thống cần được thiết kế trực quan, thân thiện và dễ thao tác nhằm nâng cao trải nghiệm người dùng. Trang chính cần hiển thị đầy đủ các chức năng

nếu tải ảnh nội soi, xem ảnh đã chọn, thực hiện dự đoán và hiển thị kết quả phân loại. Các nút chức năng cần được bố trí rõ ràng, có tên gọi dễ hiểu và phản hồi nhanh khi người dùng thao tác. Kết quả dự đoán cần được trình bày rõ ràng, bao gồm tên lớp dự đoán và mức độ tin cậy (nếu có), giúp người dùng dễ dàng theo dõi và đánh giá kết quả. Ngoài ra, giao diện cần hỗ trợ hiển thị tốt trên các trình duyệt web phổ biến, đảm bảo tính nhất quán về bố cục và chức năng trong quá trình sử dụng.

2.5. Phân tích và thiết kế mô hình nghiên cứu

Mô hình nghiên cứu của đề tài được chia thành hai hướng xử lý chính. Hướng thứ nhất là phân loại ảnh nội soi để xác định nhóm kết quả chính. Hướng thứ hai là phân đoạn vùng polyp bằng DeepLabV3+ khi ảnh được dự đoán thuộc nhóm polyp. Cách tách này giúp hệ thống vừa có kết quả tổng quát để báo cáo, vừa có vùng khoanh trực quan trong trường hợp cần quan sát tổn thương.

Ở phần phân loại, mô hình học đặc trưng từ ảnh nội soi và trả về xác suất cho từng nhãn. Trong demo, các nhãn gốc được quy về ba nhóm chính để người dùng dễ theo dõi. Các nhãn chi tiết hơn không bị bỏ đi mà được đưa vào phần phân tích chuyên sâu, giúp bác sĩ có thêm thông tin tham khảo khi mô tả nội soi.

Ở phần phân đoạn, DeepLabV3+ nhận ảnh nội soi làm đầu vào và tạo ra bản đồ xác suất vùng polyp. Sau đó hệ thống chuyển bản đồ xác suất thành mask nhị phân và tạo ảnh khoanh vùng. Nếu ảnh không thuộc nhóm polyp hoặc không có dữ liệu mask/overlay, hệ thống không đưa các ảnh này vào giao diện và PDF để tránh gây hiểu nhầm.

2.5.1 Dữ liệu đầu vào và đầu ra

Dữ liệu đầu vào của hệ thống gồm hai phần: thông tin lâm sàng ban đầu và ảnh nội soi. Thông tin lâm sàng giúp hồ sơ đầy đủ hơn khi xuất báo cáo, còn ảnh nội soi là dữ liệu chính được đưa vào mô hình. Trong phạm vi demo, mô hình chủ yếu phân tích ảnh; các thông tin triệu chứng và tiền sử được dùng để hỗ trợ bác sĩ ghi nhận trong báo cáo, không thay thế dữ liệu huấn luyện hình ảnh.

Bảng 2.2. Dữ liệu đầu vào và đầu ra của hệ thống

Thành phần	Nội dung	Vai trò trong hệ thống
Thông tin bệnh nhân	Họ tên, tuổi, giới tính, triệu chứng, tiền sử	Tạo hồ sơ và hỗ trợ bác sĩ đối chiếu khi viết kết luận
Ảnh nội soi	Ảnh JPG, JPEG hoặc PNG	Dữ liệu chính để mô hình phân tích
Kết quả phân loại	Bình thường, viêm/bất thường niêm mạc, polyp	Kết quả chính hiển thị trên giao diện
Nhãn phụ	Các nhãn chi tiết từ mô hình	Dùng làm thông tin tham khảo trong phân tích chuyên sâu
Mask và overlay	Vùng phân đoạn và vùng khoanh polyp	Chỉ xuất hiện khi có kết quả phân đoạn polyp
Báo cáo PDF	Hồ sơ bệnh án sau khi bác sĩ kiểm tra	Dùng để lưu, xem lại hoặc in kết quả

Đầu ra của hệ thống không chỉ là một nhãn dự đoán. Hệ thống trả về xác suất từng nhóm, kết quả phụ, ảnh gốc, vùng khoanh nếu có, mô tả nội soi và kết luận cuối cùng. Cách thiết kế này giúp báo cáo có nội dung gần với quy trình khám hơn thay vì chỉ là kết quả phân loại đơn lẻ.

2.5.2 Quy trình xử lý dữ liệu

Quy trình xử lý dữ liệu được chia thành hai giai đoạn: giai đoạn huấn luyện và giai đoạn chạy demo. Khi huấn luyện, dữ liệu được chia thành train, validation và test

để mô hình học và được đánh giá trên dữ liệu chưa dùng để cập nhật trọng số. Ảnh được đọc, resize, chuẩn hóa, sau đó đưa vào mô hình. Với bài toán phân đoạn, ảnh còn đi kèm mask ground truth để DeepLabV3+ học được vị trí vùng polyp ở cấp độ pixel.


Khi chạy demo, người dùng tải ảnh lên giao diện, backend kiểm tra ảnh, chuyển ảnh về định dạng phù hợp, chạy mô hình phân loại và trả về kết quả. Nếu kết quả chính là polyp, backend tiếp tục chạy DeepLabV3+ để tạo mask và ảnh khoanh vùng. Nếu không có polyp, hệ thống chỉ hiển thị ảnh gốc và kết quả phân loại.

- Bước 1: Người dùng nhập thông tin bệnh nhân và tải ảnh nội soi.
- Bước 2: Backend kiểm tra định dạng, đọc ảnh và tiền xử lý ảnh.
- Bước 3: Mô hình phân loại trả về nhóm chính và xác suất từng nhóm.
- Bước 4: Nếu kết quả là polyp, DeepLabV3+ tạo mask và vùng khoanh tổn thương.
- Bước 5: Frontend hiển thị kết quả, bác sĩ xem lại và nhập kết luận.
- Bước 6: Hệ thống lưu hồ sơ và xuất PDF khi hồ sơ đã có kết luận.

2.6. Thiết kế hệ thống

Hệ thống được thiết kế theo mô hình frontend - backend. Frontend chịu trách nhiệm giao diện, nhận thao tác từ người dùng và hiển thị kết quả. Backend chịu trách nhiệm nhận ảnh, xử lý ảnh, gọi mô hình và trả dữ liệu về giao diện. Cách tách này giúp phân giao diện và phần xử lý mô hình rõ ràng hơn, dễ kiểm tra lỗi và thuận tiện khi chạy demo trên máy khác.

Frontend của hệ thống được xây dựng bằng React và Vite. Giao diện gồm màn hình phân tích ảnh, form nhập thông tin bệnh nhân, khu vực upload ảnh, khu vực hiển thị kết quả, phần nhập kết luận của bác sĩ và màn hình lịch sử hồ sơ. Kết quả được trình bày theo hướng báo cáo: nhóm chính nằm ở phần đầu, nhãn phụ nằm trong phần phân tích chuyên sâu, còn ảnh mask/overlay chỉ hiển thị khi thật sự có dữ liệu phân đoạn.



Hình 2.2. Workflow kiến trúc frontend - backend của hệ thống.

Backend được xây dựng bằng FastAPI. Khi nhận ảnh từ frontend, backend kiểm tra ảnh, tiền xử lý, gọi mô hình phân loại và quy đổi kết quả về ba nhóm chính. Nếu ảnh thuộc nhóm polyp, backend tiếp tục gọi mô hình DeepLabV3+ để tạo mask và overlay. Kết quả cuối cùng được trả về frontend dưới dạng JSON, gồm nhãn dự đoán, xác suất, nhãn phụ, thông tin phân đoạn và các gợi ý hỗ trợ.

Báo cáo PDF được thiết kế theo dạng hồ sơ nội soi, gồm thông tin bệnh nhân, ảnh nội soi, mô tả các vùng quan sát, thông số tổn thương, kết luận và khuyến nghị. Những nội dung có tính chuyên môn được để bác sĩ kiểm tra và chỉnh sửa

2.7 Thiết kế giao diện

Giao diện hệ thống được thiết kế theo hướng trực quan, dễ sử dụng và phù hợp với quy trình làm việc của bác sĩ trong quá trình hỗ trợ chẩn đoán hình ảnh nội soi. Các thành phần trên giao diện được bố trí rõ ràng, giúp người dùng dễ dàng thao tác, theo dõi kết quả và quản lý thông tin bệnh nhân.

Màn hình chính của hệ thống bao gồm khu vực nhập thông tin bệnh nhân, cho phép người dùng điền các thông tin cơ bản như mã bệnh nhân, họ tên, giới tính, tuổi và các thông tin cần thiết khác phục vụ việc lưu trữ và tra cứu hồ sơ. Tiếp theo là khu vực tải ảnh nội soi, hỗ trợ người dùng lựa chọn hoặc kéo thả ảnh từ thiết bị. Hệ thống cần kiểm tra định dạng tệp, hiển thị ảnh xem trước sau khi tải lên và thông báo khi ảnh không hợp lệ hoặc quá trình tải lên gặp lỗi.


Sau khi ảnh được xử lý, kết quả phân tích sẽ được hiển thị tại khu vực kết quả. Thông tin được sắp xếp theo thứ tự ưu tiên, trong đó kết quả phân loại chính được đặt ở vị trí nổi bật nhằm giúp người dùng nhanh chóng nhận biết nhóm bệnh hoặc tổn thương

được dự đoán. Các thông tin phân tích chi tiết như nhãn phụ, xác suất dự đoán hoặc các đặc trưng liên quan được trình bày ở phần mở rộng để hỗ trợ việc đánh giá chuyên sâu. Nếu mô hình có thực hiện phân đoạn vùng tổn thương, hệ thống sẽ hiển thị ảnh mask hoặc ảnh overlay chồng lên ảnh gốc để minh họa vị trí bất thường; ngược lại, phần này sẽ được ẩn nhằm tránh gây rối giao diện.

Bên cạnh kết quả dự đoán, giao diện còn có phần nhập kết luận của bác sĩ, cho phép bổ sung nhận xét, chẩn đoán lâm sàng và các khuyến nghị điều trị. Nội dung này được lưu cùng hồ sơ bệnh nhân để phục vụ quá trình theo dõi và đối chiếu với kết quả dự đoán của hệ thống.

The screenshot displays the 'GastroVision AI' web application interface. On the left is a dark sidebar with navigation links: 'Phân tích ảnh' (Image Analysis) and 'Lịch sử' (History). The main content area is titled 'HỒ SƠ NỘI SOI DẠ DÀY' (Gastric Endoscopy History) and includes a form for patient information. The form fields include: 'Họ tên' (Name) with the value 'Nguyễn Văn A', 'Tuổi' (Age) with the value '45', 'Giới tính' (Gender) with a dropdown menu, and 'Triệu chứng hiện tại' (Current symptoms) with a text area containing 'Đau thượng vị, buồn nôn, sụt cân, xuất huyết tiêu hóa...'. Below this is a section for 'Tiền sử bệnh dạ dày / lần khám trước' (Previous gastric disease / last examination) with a text area containing 'Viêm dạ dày năm 2024, đã điều trị HP, từng nội soi/cắt polyp...'. To the right of the form is an 'Upload ảnh nội soi' (Upload endoscopy image) section with a button 'Chọn ảnh hoặc kéo thả vào đây' (Choose image or drag and drop here). Below this is an 'Ảnh xem trước' (Preview image) section. At the bottom of the form is a 'KẾT QUẢ PHÂN TÍCH' (Analysis Results) section with a button 'Chờ phân tích ảnh' (Waiting for image analysis).

Hình 2.3 Giao diện màn phân tích ảnh



Hình 2.4 Giao diện màn hình Lịch sử hồ sơ


Màn hình lịch sử dùng để xem lại các hồ sơ nội soi đã được lưu sau khi phân tích. Tại đây, người dùng có thể xem thông tin tóm tắt của từng hồ sơ như tên bệnh nhân, ảnh nội soi, kết quả dự đoán, thời gian tạo hồ sơ và trạng thái phân đoạn nếu có. Màn hình cũng hỗ trợ xem lại hoặc tải báo cáo PDF, đồng thời cho phép xóa lịch sử khi không còn cần lưu trên trình duyệt.

2.8 Phân tích về thiết kế UML

2.8.1. Sơ đồ chức năng BFD

Sơ đồ BFD được sử dụng để mô tả các chức năng của hệ thống theo dạng phân rã từ tổng quát đến chi tiết. Chức năng lớn nhất của hệ thống là hỗ trợ phân tích ảnh nội soi bằng AI. Từ chức năng này, hệ thống được chia thành các nhóm chức năng nhỏ hơn.

Sơ đồ trên cho thấy hệ thống GastroVision AI được phát triển nhằm hỗ trợ phân tích ảnh nội soi bằng trí tuệ nhân tạo. Người dùng tải ảnh nội soi lên hệ thống, sau đó ảnh sẽ được kiểm tra tính hợp lệ và gửi đến máy chủ để xử lý. Tại đây, ảnh được tiền xử lý trước khi đưa vào mô hình ResNet50 để phân loại và dự đoán sự xuất hiện của polyp. Tiếp theo, mô hình DeepLabV3+ được sử dụng để xác định vị trí polyp và tạo ảnh đánh dấu vùng tổn thương.



Hình 2.5 Sơ đồ BFD

Kết quả phân tích được hiển thị dưới dạng nhãn dự đoán, độ tin cậy và ảnh minh họa nếu có. Ngoài ra, hệ thống còn cung cấp các thông báo lỗi khi tệp không hợp lệ, cảnh báo đối với các kết quả có độ tin cậy thấp và nhắc nhở rằng kết quả từ AI chỉ mang tính chất hỗ trợ, không thay thế cho chẩn đoán của bác sĩ.


2.8.2. Sơ đồ Use Case

Sơ đồ Use Case mô tả các thao tác chính mà người dùng có thể thực hiện với hệ thống. Trong hệ thống này, người dùng hoặc bác sĩ là tác nhân thao tác trực tiếp với giao diện.

Sơ đồ use case mô tả các chức năng chính của hệ thống hỗ trợ phân tích ảnh nội soi. Hệ thống hỗ trợ bác sĩ trong quá trình phân loại và chuẩn đoán bệnh. Bác sĩ sẽ nhập hồ sơ bệnh nhân gồm có Họ và tên, tuổi, giới tính, triệu chứng, có thể nhập thêm kết quả từ lần khám trước để bác sĩ dễ dàng nắm được tình hình của bệnh nhân. Sau khi có được dữ liệu của bệnh nhân, bác sĩ sẽ gửi ảnh nội soi để hệ thống chạy phân tích, đối với những kết quả phân tích chỉ hỗ trợ bác sĩ, vẫn cần phải dựa vào kinh nghiệm của bác sĩ chuyên khoa để chẩn đoán và kết luận. Hệ thống có xuất thêm những lưu ý giúp bác sĩ chú ý tới những điểm cần để cho ra được kết quả tốt nhất.

Ngoài chức năng phân tích ảnh, hệ thống còn hỗ trợ xem lịch sử hồ sơ, cho phép bác sĩ tra cứu các ca bệnh đã được lưu trước đó. Người dùng có thể xem lại thông tin bệnh nhân, ảnh nội soi, kết quả phân tích và kết luận đã được ghi nhận. Bên cạnh đó, hệ

thống cung cấp chức năng xem hoặc tải báo cáo dưới dạng PDF, giúp thuận tiện trong việc lưu trữ, chia sẻ hoặc in kết quả khi cần thiết. Trong trường hợp cần quản lý dữ liệu, bác sĩ cũng có thể xóa hồ sơ không còn sử dụng nhằm đảm bảo cơ sở dữ liệu luôn được cập nhật.



Hình 2.6 Sơ đồ use case

2.9 Nhận xét về thiết kế hệ thống

Hệ thống được xây dựng theo mô hình Frontend – Backend, trong đó frontend đảm nhiệm việc hiển thị giao diện và tương tác với người dùng, còn backend chịu trách nhiệm xử lý dữ liệu, quản lý cơ sở dữ liệu và giao tiếp với các mô hình AI. Cách thiết kế này giúp hệ thống có cấu trúc rõ ràng, dễ quản lý và thuận tiện cho việc bảo trì hoặc phát triển thêm các chức năng sau này.

Về chức năng, hệ thống đã đáp ứng được các yêu cầu đặt ra trong phạm vi đề tài. Người dùng có thể tạo hồ sơ bệnh nhân, tải ảnh nội soi lên hệ thống, thực hiện phân tích bằng AI, xem kết quả dự đoán, chỉnh sửa nhận xét, nhập kết luận cuối cùng của bác sĩ, lưu lại lịch sử khám và xuất báo cáo dưới dạng PDF. Các chức năng được liên kết thành

một quy trình thống nhất, giúp giảm thao tác thủ công và hỗ trợ quá trình đọc ảnh nội soi thuận tiện hơn.

Đối với phân xử lý ảnh, hệ thống kết hợp hai mô hình AI để tận dụng ưu điểm của từng mô hình. Mô hình ResNet-50 kết hợp SVM được sử dụng để phân loại ảnh thành ba nhóm gồm Normal, Esophagitis và Polyps. Nếu ảnh được dự đoán là Polyps, hệ thống sẽ tiếp tục sử dụng DeepLabV3+ để phân đoạn và khoanh vùng vị trí polyp trên ảnh nội soi. Cách xử lý này giúp giảm thời gian tính toán vì chỉ những ảnh nghi ngờ có polyp mới cần thực hiện bước phân đoạn, đồng thời kết quả hiển thị trực quan hơn, hỗ trợ bác sĩ quan sát tổn thương dễ dàng.

Hệ thống cũng có khả năng lưu trữ thông tin bệnh nhân, hình ảnh nội soi, kết quả phân tích AI và kết luận cuối cùng. Điều này giúp người dùng có thể tra cứu lại các lần khám trước, đồng thời hỗ trợ quản lý dữ liệu một cách thuận tiện hơn.

Mặc dù đã đạt được mục tiêu của đề tài, hệ thống vẫn còn một số hạn chế. Bộ dữ liệu sử dụng để huấn luyện còn tương đối nhỏ và chủ yếu là dữ liệu công khai nên chưa phản ánh đầy đủ các trường hợp trong thực tế. Hệ thống hiện chỉ hỗ trợ phân loại ba nhóm ảnh và chưa tích hợp các chức năng bảo mật hoặc phân quyền người dùng như trong các hệ thống bệnh viện. Ngoài ra, kết quả của mô hình AI chỉ mang tính chất hỗ trợ tham khảo, không thể thay thế hoàn toàn cho kết luận của bác sĩ chuyên khoa.

Trong thời gian tới, hệ thống có thể được phát triển theo hướng mở rộng bộ dữ liệu huấn luyện, bổ sung thêm nhiều bệnh lý đường tiêu hóa khác, nâng cao độ chính xác của mô hình và cải thiện tốc độ xử lý. Bên cạnh đó, việc bổ sung các chức năng như phân quyền người dùng, bảo mật dữ liệu và kết nối với hệ thống quản lý bệnh viện sẽ giúp hệ thống có tính ứng dụng cao hơn trong thực tế. Trước khi triển khai trong môi trường lâm sàng, hệ thống cũng cần được kiểm thử trên nhiều nguồn dữ liệu và đánh giá bởi các bác sĩ chuyên khoa để đảm bảo độ tin cậy và tính an toàn khi sử dụng.

CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ HỆ THỐNG

3.1 Phân tích dữ liệu nghiên cứu

Dữ liệu sử dụng trong đồ án là tập ảnh nội soi đường tiêu hóa được thu thập từ các nguồn dữ liệu y tế uy tín. Các ảnh trong bộ dữ liệu đã được gán nhãn bởi các bác sĩ chuyên gia có kinh nghiệm trong lĩnh vực nội soi tiêu hóa. Nhờ đó, dữ liệu có độ tin cậy cao hơn so với dữ liệu tự thu thập chưa qua kiểm chứng.

Trong phạm vi hệ thống GastroVision AI, dữ liệu được sử dụng cho hai nhiệm vụ chính. Nhiệm vụ thứ nhất là phân loại ảnh nội soi vào các nhóm bệnh lý. Nhiệm vụ thứ hai là phân đoạn vùng tổn thương polyp trên ảnh nội soi. Hai nhiệm vụ này hỗ trợ lẫn nhau trong quá trình xây dựng hệ thống: mô hình phân loại giúp nhận biết ảnh thuộc nhóm nào, còn mô hình phân đoạn giúp xác định vị trí vùng nghi ngờ trên ảnh.

Bảng 3.1 Các lớp dữ liệu trong bộ dữ liệu HyperKvasir [9]

STT	Lớp dữ liệu	Nhóm	Mô tả
1	Barrett's esophagus	Bệnh lý	Thực quản Barrett, niêm mạc thực quản bị biến đổi do trào ngược kéo dài.
2	Barrett's esophagus (short segment)	Bệnh lý	Thực quản Barrett đoạn ngắn.
3	Esophagitis	Bệnh lý	Viêm thực quản với các mức độ tổn thương niêm mạc khác nhau.
4	Normal Z-line	Giải phẫu	Vùng nối giữa thực quản và dạ dày ở trạng thái bình thường.
5	Hiatal hernia	Bệnh lý	Thoát vị khe hoành.
6	Gastritis	Bệnh lý	Viêm niêm mạc dạ dày.
7	Pylorus	Giải phẫu	Môn vị bình thường.
8	Polyps	Bệnh lý	Hình ảnh có polyp trong đường tiêu hóa.

9	Dyed-lifted polyps	Thủ thuật	Polyp sau khi được tiêm thuốc nhuộm để nâng tổn thương.
10	Dyed resection margins	Thủ thuật	Vùng rìa sau khi cắt polyp được nhuộm màu.
11	Ulcerative colitis	Bệnh lý	Viêm loét đại tràng.
12	Cecum	Giải phẫu	Hình ảnh manh tràng.
13	Ileum	Giải phẫu	Hình ảnh hồi tràng.
14	Retroflex rectum	Giải phẫu	Hình ảnh trực tràng ở tư thế nội soi ngược.
15	Retroflex stomach	Giải phẫu	Hình ảnh dạ dày ở tư thế nội soi ngược.
16	Hemorrhoids	Bệnh lý	Hình ảnh bệnh trĩ.
17	Impacted stool	Khác	Phân cứng hoặc phân tồn đọng trong lòng ruột.
18	Blood - fresh	Khác	Hình ảnh máu tươi trong đường tiêu hóa.
19	Blood - hematin	Khác	Hình ảnh máu đã oxy hóa (hematin).
20	Foreign body	Khác	Hình ảnh dị vật trong đường tiêu hóa.
21	Normal mucosa	Giải phẫu	Niêm mạc đường tiêu hóa bình thường.
22	Stool inclusions	Khác	Phân hoặc cặn bã che khuất hình ảnh.
23	Instrument	Thủ thuật	Dụng cụ nội soi xuất hiện trong ảnh.
24	Blurry image	Chất lượng ảnh	Ảnh bị mờ hoặc mất nét.
25	Bubbles	Chất lượng ảnh	Ảnh có nhiều bọt khí.

26	Low quality image	Chất lượng ảnh	Ảnh có chất lượng thấp do ánh sáng hoặc nhiễu.
27	Undefined/ Miscellaneous	Khác	Các ảnh không thuộc các nhóm trên hoặc khó phân loại.

Đối với bài toán phân loại, mỗi ảnh được gán một nhãn tương ứng với tình trạng bệnh lý. Trong đề án này, hệ thống tập trung vào ba nhóm chính:

- normal: ảnh nội soi bình thường
- esophagitis: ảnh viêm thực quản
- polyps: ảnh có polyp

Đối với bài toán phân đoạn, dữ liệu gồm ảnh nội soi và mặt nạ tương ứng. Mặt nạ là ảnh nhị phân biểu diễn vùng tổn thương polyp. Vùng tổn thương được đánh dấu khác với vùng nền, giúp mô hình học được vị trí cần phân đoạn ở mức pixel. Đây là dạng dữ liệu quan trọng trong bài toán ảnh y tế, vì ngoài việc biết ảnh có tổn thương hay không, hệ thống còn cần chỉ ra vùng nghi ngờ để người dùng dễ quan sát.

Trước khi huấn luyện, dữ liệu được chia thành các tập riêng biệt gồm tập huấn luyện, tập kiểm định và tập kiểm thử. Tập huấn luyện được dùng để cập nhật trọng số mô hình. Tập kiểm định được dùng để theo dõi quá trình học và chọn ngưỡng dự đoán phù hợp. Tập kiểm thử chỉ được dùng sau cùng để đánh giá khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng thấy.

3.1.1 Quy trình xử lý dữ liệu

3.1.1.1 Tổng quan pipeline xử lý

Quy trình xử lý dữ liệu trong đề án được xây dựng để đưa ảnh nội soi và mặt nạ về đúng định dạng đầu vào của mô hình. Dữ liệu ban đầu có thể khác nhau về kích thước, chất lượng ảnh, độ sáng và định dạng. Nếu đưa trực tiếp vào mô hình, quá trình huấn luyện dễ bị nhiễu và kết quả không ổn định. Vì vậy, dữ liệu cần được kiểm tra, chuẩn hóa và tổ chức thành pipeline rõ ràng trước khi train.

Pipeline xử lý dữ liệu cho mô hình phân đoạn polyp được thực hiện theo các bước chính sau:

Trong quá trình xử lý, tập kiểm thử được giữ riêng và không tham gia vào quá trình huấn luyện hoặc chọn tham số. Việc này giúp hạn chế rò rỉ dữ liệu, đồng thời đảm bảo kết quả đánh giá phản ánh đúng khả năng của mô hình khi gặp dữ liệu mới.

Trước khi train, một số mẫu ảnh được hiển thị cùng với mặt nạ thật và ảnh overlay. Bước này giúp kiểm tra trực quan xem vùng mask có đúng với vị trí tổn thương hay không. Nếu mặt nạ bị lệch, sai vùng hoặc sai kích thước, mô hình có thể học sai ngay từ đầu. Vì vậy, việc kiểm tra ảnh và mask trước khi huấn luyện là bước cần thiết trong pipeline.

Sau khi dữ liệu được xử lý, mô hình DeepLabv3+ được huấn luyện để học cách tạo mặt nạ phân đoạn polyp. Sau khi huấn luyện xong, mô hình tốt nhất được lưu lại và tích hợp vào hệ thống website. Khi người dùng tải ảnh lên, hệ thống thực hiện tiền xử lý ảnh, dự đoán nhãn, tạo mask nếu phát hiện polyp và hiển thị kết quả trên giao diện.

3.1.1.2 Tiền xử lý dữ liệu

Tiền xử lý dữ liệu là bước đưa ảnh về cùng một chuẩn trước khi huấn luyện. Trong đồ án, ảnh nội soi được đọc ở dạng ảnh màu RGB để đảm bảo thống nhất ba kênh màu. Việc chuyển về RGB giúp tránh trường hợp ảnh đầu vào có định dạng khác nhau, ví dụ ảnh xám hoặc ảnh có kênh alpha.

Đối với mô hình phân đoạn DeepLabv3+, ảnh và mặt nạ được resize về kích thước `352x352`. Ảnh được resize bằng phương pháp nội suy bilinear vì ảnh màu là dữ liệu liên tục, việc nội suy giúp ảnh sau resize mượt hơn. Ngược lại, mặt nạ được resize bằng nearest interpolation vì mặt nạ là dữ liệu nhãn. Nếu dùng bilinear cho mặt nạ, các giá trị trung gian có thể xuất hiện và làm sai nhãn pixel.

Sau khi resize, mặt nạ được nhị phân hóa lại. Các pixel thuộc vùng polyp được gán giá trị `1`, còn các pixel nền được gán giá trị `0`. Việc đưa mặt nạ về dạng nhị phân giúp mô hình học bài toán phân đoạn hai lớp: nền và polyp.

Đối với mô hình phân loại, ảnh được resize về kích thước `224x224` để phù hợp với đầu vào của ResNet50. Ảnh sau đó được chuyển thành mảng số, chuẩn hóa giá trị điểm ảnh và chuyển thành tensor trước khi đưa vào mô hình.

3.1.1.3. Xử lý mặt nạ và gom nhóm nhãn

Trong bài toán phân đoạn, mặt nạ đóng vai trò là nhãn ở cấp độ pixel. Mỗi pixel trong mặt nạ cho biết vị trí đó thuộc vùng nền hay vùng polyp. Do đó, chất lượng mặt nạ ảnh hưởng trực tiếp đến khả năng học của mô hình DeepLabv3+.

Các mặt nạ được xử lý về dạng nhị phân. Vùng polyp được biểu diễn bằng giá trị `1`, vùng nền được biểu diễn bằng giá trị `0`. Khi resize mặt nạ, hệ thống sử dụng nearest interpolation để giữ nguyên ý nghĩa nhãn. Sau khi resize, mặt nạ tiếp tục được kiểm tra và nhị phân hóa để đảm bảo không còn giá trị trung gian.

Đối với nhãn phân loại, dữ liệu được gom về ba nhóm chính là `normal`, `esophagitis` và `polyps`. Việc gom nhóm giúp bài toán rõ ràng hơn và phù hợp với phạm vi nhận diện của hệ thống. Sau khi gom nhóm, nhãn dạng chữ được mã hóa thành nhãn số để mô hình có thể xử lý.

3.1.1.4. Tăng cường dữ liệu

Trong quá trình train mô hình phân đoạn, hệ thống áp dụng tăng cường dữ liệu cho tập train. Mục đích của bước này là tạo thêm các biến thể hợp lý từ ảnh gốc, giúp mô hình bớt phụ thuộc vào một kiểu ảnh cố định và giảm nguy cơ overfitting.

Các phép biến đổi hình học như lật và xoay được áp dụng đồng thời cho cả ảnh và mặt nạ. Điều này đảm bảo vùng polyp trên mặt nạ vẫn khớp với vị trí tổn thương trên ảnh. Riêng thay đổi độ sáng và độ tương phản chỉ áp dụng cho ảnh, không áp dụng cho mặt nạ, vì mặt nạ là nhãn phân đoạn và không được làm thay đổi giá trị.

Tăng cường dữ liệu chỉ được áp dụng trên tập train. Tập validation và test không áp dụng augmentation để kết quả đánh giá phản ánh đúng dữ liệu thực tế.

3.1.1.5. Trích xuất đặc trưng

Trong đề án, quá trình trích xuất đặc trưng được thực hiện tự động thông qua các mô hình học sâu. Với mô hình phân đoạn, DeepLabv3+ sử dụng encoder ResNet50 để trích xuất đặc trưng từ ảnh nội soi. Các lớp đầu của ResNet50 học các đặc trưng đơn

giản như cạnh, màu sắc và vùng sáng tối. Các lớp sâu hơn học những đặc trưng phức tạp hơn như cấu trúc niêm mạc, hình dạng vùng tổn thương và đặc điểm bất thường.

Trong DeepLabv3+, đặc trưng mức cao được dùng để nhận biết ngữ cảnh của vùng tổn thương, còn đặc trưng mức thấp giúp giữ lại thông tin vị trí và đường biên. Sự kết hợp này giúp mô hình vừa nhận biết được vùng polyp, vừa tạo được mặt nạ có ranh giới rõ hơn.

Với mô hình phân loại, ResNet50 cũng được dùng để trích xuất đặc trưng ảnh. Sau phần trích xuất đặc trưng, lớp phân loại cuối cùng đưa ra xác suất cho từng nhóm nhãn. Nhãn có xác suất cao nhất được chọn làm kết quả dự đoán.

3.1.1.6. Sinh nhãn phân loại


Sau khi dữ liệu được gom nhóm, mỗi ảnh được gán một nhãn phân loại tương ứng. Nhãn chữ được chuyển thành nhãn số để mô hình có thể sử dụng trong quá trình huấn luyện. Mỗi mẫu dữ liệu phân loại gồm ảnh đầu vào và nhãn tương ứng.

Trong quá trình huấn luyện, mô hình dự đoán nhãn của ảnh rồi so sánh với nhãn thật. Từ sai số này, mô hình cập nhật trọng số để cải thiện khả năng phân loại ở các epoch tiếp theo.

3.2 Xử lý SVM

Hình biểu đồ phân bố dữ liệu thể hiện số lượng ảnh thuộc ba lớp normal, esophagitis và polyps trong các tập train, validation và test. Việc quan sát biểu đồ này giúp đánh giá mức độ cân bằng của dữ liệu giữa các lớp. Khi số lượng mẫu giữa các lớp không chênh lệch quá lớn, mô hình sẽ hạn chế được tình trạng thiên lệch về lớp có nhiều dữ liệu hơn. Đây là cơ sở quan trọng để đảm bảo kết quả huấn luyện và đánh giá mô hình có độ tin cậy.

Biểu đồ cho thấy dữ liệu phân loại gồm ba lớp là esophagitis, normal và polyps. Mỗi lớp có số lượng ảnh bằng nhau trong cả ba tập dữ liệu: 700 ảnh ở tập huấn luyện, 150 ảnh ở tập validation và 150 ảnh ở tập test. Như vậy, mỗi lớp có tổng cộng 1.000 ảnh và toàn bộ dữ liệu gồm 3.000 ảnh.




Hình 3.1 Phân bố số lượng ảnh theo lớp

Bên cạnh đó, tập test gồm 450 ảnh, trong đó mỗi lớp có 150 ảnh. Cách chia này giúp việc quan sát ma trận nhầm lẫn và so sánh khả năng phân loại giữa ba lớp trở nên rõ ràng hơn.

Biểu đồ thể hiện sự thay đổi của hàm mất mát trên tập train và validation qua từng epoch trong quá trình huấn luyện ResNet-50. Train Loss giảm dần cho thấy mô hình đã học được các đặc trưng từ dữ liệu huấn luyện. Validation Loss đạt giá trị thấp nhất tại Epoch 2, bằng 0.1749, do đó checkpoint tại epoch này được lựa chọn làm mô hình ResNet-50 tốt nhất.

Từ Epoch 3 trở đi, Train Loss tiếp tục giảm nhưng Validation Loss không tiếp tục cải thiện và có xu hướng tăng. Điều này cho thấy mô hình bắt đầu xuất hiện dấu hiệu overfitting nhẹ, tức là mô hình học tốt trên dữ liệu train nhưng khả năng tổng quát hóa trên tập validation không tăng tương ứng. Vì vậy, cơ chế Early Stopping được sử dụng để dừng quá trình train khi Validation Loss không còn cải thiện.

Biểu đồ thể hiện sự thay đổi của hàm mất mát trên tập train và validation trong quá trình huấn luyện ResNet-50. Ở Epoch 1, Train Loss có giá trị khoảng 0,4851 và Validation Loss là 0,2385. Sang Epoch 2, cả hai chỉ số đều giảm mạnh, trong đó Validation Loss đạt giá trị thấp nhất là 0,1749.



Hình 3.2. Biểu đồ Train Loss và Validation Loss

Validation Loss thấp nhất tại Epoch 2 cho thấy mô hình ở thời điểm này có khả năng tổng quát hóa tốt nhất trên tập validation. Vì notebook sử dụng Validation Loss làm tiêu chí lựa chọn checkpoint, model tại Epoch 2 được lưu lại làm mô hình ResNet-50 tốt nhất.

Từ Epoch 3 đến Epoch 7, Train Loss tiếp tục giảm từ khoảng 0,0958 xuống còn 0,0219. Điều này cho thấy mô hình ngày càng học sát hơn các đặc trưng của tập train. Tuy nhiên, Validation Loss sau Epoch 2 lại tăng từ 0,1961 lên khoảng 0,2397 tại Epoch 7. Mặc dù Validation Loss ở Epoch 7 có giảm nhẹ so với Epoch 6, giá trị này vẫn cao hơn đáng kể so với Epoch 2.

Sự khác biệt giữa xu hướng Train Loss và Validation Loss cho thấy mô hình bắt đầu có dấu hiệu overfitting nhẹ. Cụ thể, mô hình tiếp tục cải thiện trên dữ liệu huấn luyện nhưng không cải thiện tương ứng trên dữ liệu validation. Vì sau Epoch 2 có 5 epoch liên tiếp không đạt Validation Loss tốt hơn, cơ chế Early Stopping đã dừng quá trình huấn luyện tại Epoch 7.


Biểu đồ Accuracy thể hiện độ chính xác của mô hình ResNet-50 trên tập train và validation qua từng epoch. Kết quả cho thấy Train Accuracy tăng dần trong quá trình

huấn luyện, chứng tỏ mô hình đã học được các đặc trưng giúp phân biệt ba lớp ảnh nội soi.

Validation Accuracy đạt mức cao nhất khoảng 93,33%. Tuy nhiên, sau các epoch tiếp theo, chỉ số này không tăng ổn định trong khi Train Accuracy vẫn tiếp tục tăng. Khoảng cách giữa Accuracy của train và validation cho thấy mô hình có dấu hiệu overfitting nhẹ. Kết quả này phù hợp với nhận xét từ biểu đồ Loss. Hai biểu đồ Loss và Accuracy được sử dụng để lựa chọn checkpoint ResNet-50 phù hợp trước khi trích xuất đặc trưng và đưa vào mô hình SVM.

Biểu đồ Accuracy cho thấy khả năng phân loại đúng của mô hình trên tập train và validation qua từng epoch. Train Accuracy tăng từ 81,86% ở Epoch 1 lên 99,24% ở Epoch 7. Kết quả này cho thấy ResNet-50 đã học tốt các đặc trưng của dữ liệu huấn luyện.

Đối với tập validation, Accuracy dao động trong khoảng từ 90,44% đến 93,33%. Giá trị Validation Accuracy cao nhất xuất hiện tại Epoch 3, đạt 93,33%. Tuy nhiên, notebook không lựa chọn Epoch 3 làm checkpoint tốt nhất vì tiêu chí lựa chọn model là Validation Loss, không phải Validation Accuracy.



Hình 3.3. Biểu đồ Train Accuracy và Validation Accuracy

Tại Epoch 2, Validation Accuracy đạt 92,67% và Validation Loss đạt mức thấp nhất là 0,1749. Trong khi đó, Epoch 3 có Validation Accuracy cao hơn một chút nhưng Validation Loss tăng lên 0,1961. Điều này cho thấy Epoch 3 có thể dự đoán đúng nhiều ảnh hơn, nhưng một số dự đoán sai có mức độ tự tin cao hơn, làm cho hàm mất mát tăng lên.

Từ Epoch 3 trở đi, Train Accuracy gần đạt 100% nhưng Validation Accuracy chỉ dao động quanh 91% đến 93%. Khoảng cách này tiếp tục cho thấy mô hình có dấu hiệu overfitting nhẹ. Vì vậy, việc giữ checkpoint tại Epoch 2 là phù hợp hơn cho bước trích xuất đặc trưng và huấn luyện Linear SVM.

Lưu ý rằng hai biểu đồ Loss và Accuracy chỉ phản ánh quá trình huấn luyện ResNet-50. Linear SVM không được train theo từng epoch như mạng nơ-ron nên không có biểu đồ Loss hoặc Accuracy theo epoch.

Ma trận nhầm lẫn thể hiện kết quả phân loại của mô hình ResNet-50 kết hợp Linear SVM trên tập test. Trong đó, ResNet-50 được sử dụng để trích xuất vector đặc trưng 2.048 chiều từ ảnh nội soi, sau đó Linear SVM sử dụng các đặc trưng này để phân loại ảnh thành ba lớp normal, esophagitis và polyps.

Các giá trị nằm trên đường chéo chính của ma trận thể hiện số lượng ảnh được dự đoán đúng theo

Ma trận nhầm lẫn được sử dụng để đánh giá chi tiết khả năng phân loại của mô hình ResNet-50 kết hợp Linear SVM trên tập test gồm 450 ảnh. Trong đó, ResNet-50 có nhiệm vụ trích xuất vector đặc trưng 2.048 chiều từ ảnh nội soi, sau đó Linear SVM sử dụng vector đặc trưng này để phân loại ảnh thành ba lớp esophagitis, normal và polyps.

Trong ma trận nhầm lẫn, các hàng thể hiện nhãn thực tế của ảnh, còn các cột thể hiện nhãn mà mô hình dự đoán. Các ô nằm trên đường chéo chính biểu thị số lượng ảnh được dự đoán đúng. Các ô nằm ngoài đường chéo biểu thị số lượng ảnh bị dự đoán nhầm sang lớp khác.

Kết quả cụ thể như sau:

Bảng 3.2 Phân tích kết quả phân loại từ ma trận nhầm lẫn

Lớp thực tế	Dự đoán đúng	Dự đoán nhầm	Nhận xét
esophagitis	124/150 ảnh	25 ảnh nhầm thành normal, 1 ảnh nhầm thành polyps	Đây là lớp có Recall thấp nhất, đạt khoảng 82,67%
normal	127/150 ảnh	21 ảnh nhầm thành esophagitis, 2 ảnh nhầm thành polyps	Mô hình chủ yếu nhầm giữa normal và esophagitis
polyps	146/150 ảnh	4 ảnh nhầm thành normal, không có ảnh nhầm thành esophagitis	Đây là lớp được nhận diện tốt nhất

Kết quả cho thấy lớp polyps có hiệu quả nhận diện tốt nhất. Cụ thể, mô hình phát hiện đúng 146 trên 150 ảnh polyp, tương đương Recall khoảng 97,33%. Ngoài ra, trong tổng số 149 ảnh được mô hình dự đoán là polyp, có 146 ảnh đúng, tương đương Precision khoảng 97,99%.

Điều này cho thấy mô hình có khả năng nhận diện polyp khá tốt, phù hợp với luồng xử lý của website. Khi SVM dự đoán ảnh thuộc lớp polyps, hệ thống sẽ tiếp tục gọi DeepLabV3+ để thực hiện phân đoạn và khoanh vùng polyp.

Ngược lại, lỗi dự đoán tập trung chủ yếu giữa hai lớp esophagitis và normal. Có 25 ảnh viêm thực quản bị nhầm thành bình thường, đồng thời có 21 ảnh bình thường bị nhầm thành viêm thực quản. Kết quả này cho thấy đặc điểm hình ảnh giữa hai lớp có thể có sự tương đồng nhất định, chẳng hạn khác biệt về màu sắc hoặc mức độ viêm không rõ ràng trên một số ảnh nội soi.

Các chỉ số theo từng lớp được tóm tắt như sau:

Bảng 3.3 Kết quả đánh giá hiệu quả phân loại của mô hình

Lớp	Precision	Recall	F1-score	Lớp
Esophagitis	85,52%	82,67%	84,07%	Esophagitis
Normal	81,41%	84,67%	83,01%	Normal
Polyps	97,99%	97,33%	97,66%	Polyps
Trung bình macro	88,30%	88,22%	88,24%	Trung bình macro


Từ ma trận nhầm lẫn có thể nhận thấy mô hình ResNet-50 kết hợp Linear SVM hoạt động tốt trên lớp polyps, trong khi hai lớp normal và esophagitis vẫn là nhóm cần được cải thiện thêm trong các nghiên cứu sau. Một số hướng cải thiện có thể là bổ sung thêm ảnh đa dạng cho hai lớp này, tăng cường dữ liệu phù hợp hoặc thử nghiệm các phương pháp trích xuất đặc trưng khác.

3.3 Xử lý Deeplabv3+


Tập train được dùng trực tiếp trong quá trình huấn luyện. Tập validation không dùng để cập nhật trọng số mà dùng để theo dõi mô hình và chọn ngưỡng phân đoạn phù hợp. Tập test chỉ được dùng sau khi mô hình đã huấn luyện xong, nhằm đánh giá khách quan hơn. Việc giữ riêng tập ETIS làm external test giúp hạn chế rò rỉ dữ liệu và kiểm tra xem mô hình có hoạt động ổn định trên nguồn ảnh khác hay không.

Hình minh họa dữ liệu phân đoạn gồm ba phần: ảnh nội soi gốc, mặt nạ chuẩn và ảnh overlay giữa ảnh gốc với mask. Việc kiểm tra trực quan các mẫu này được thực hiện trước khi train để đảm bảo ảnh và mask khớp nhau.

Kết quả huấn luyện cho thấy hàm mất mát trên cả tập huấn luyện và tập validation đều giảm theo số epoch. Đồng thời, chỉ số Dice tăng dần và ổn định ở giai đoạn cuối của quá trình huấn luyện. Dice trên tập validation đạt khoảng 0,87, cho thấy mô hình có khả năng xác định vùng polyp tương đối chính xác. Mặc dù có khoảng cách nhất định giữa kết quả train và validation ở các epoch cuối, validation loss và validation Dice vẫn ổn định, do đó mô hình chưa xuất hiện tình trạng quá khớp nghiêm trọng.



Hình 3.4. Một số mẫu ảnh, mask và overlay dùng cho bài toán phân đoạn polyp.




Hình 3.5 Biểu đồ Loss và Dice theo epoch

Kết quả dự đoán segmentation


Sau khi mô hình phân loại xác định ảnh nội soi thuộc lớp Polyps, hệ thống sẽ tự động chuyển ảnh sang mô hình DeepLabV3+ để thực hiện phân đoạn vùng tổn thương. Kết quả được hiển thị trực quan trên giao diện dưới dạng mặt nạ phân đoạn (segmentation mask), giúp làm nổi bật vị trí nghi ngờ có polyp trên ảnh nội soi.

Bên cạnh ảnh gốc, hệ thống hiển thị thêm ảnh kết quả sau khi phân đoạn để người dùng dễ dàng so sánh và quan sát sự khác biệt. Vùng được mô hình xác định là polyp sẽ được đánh dấu rõ ràng, hỗ trợ bác sĩ xác định vị trí tổn thương nhanh hơn trong quá trình

đánh giá hình ảnh. Nếu ảnh không được phân loại là Polyps, hệ thống sẽ không thực hiện bước phân đoạn mà chỉ hiển thị kết quả phân loại tương ứng.



Hình 3.6 Kết quả sau khi train mô hình lần 1



Hình 3.7 Kết quả sau khi train mô hình lần 2

Kết quả trực quan cho thấy mô hình có thể xác định tương đối chính xác các tổn thương có kích thước trung bình và lớn. Tuy nhiên, với các polyp nhỏ hoặc có đặc điểm hình ảnh không rõ ràng, mô hình vẫn có thể bỏ sót hoặc dự đoán sai vị trí. Điều này cho thấy mô hình có tiềm năng hỗ trợ phát hiện tổn thương, nhưng chưa thể thay thế hoàn toàn việc đánh giá của bác sĩ chuyên môn.

KẾT LUẬN VÀ KIẾN NGHỊ

1. Kết luận

1.1 Kết luận về mặt lý thuyết

Đề tài đã vận dụng cơ sở lý thuyết về học sâu trong xử lý ảnh y khoa để xây dựng hướng tiếp cận hỗ trợ phân tích ảnh nội soi dạ dày. Trong đó, bài toán được chia thành hai nhiệm vụ chính gồm phân loại ảnh nội soi và phân đoạn vùng tổn thương nghi ngờ.

Đối với bài toán phân loại, ResNet50 được sử dụng để tự động trích xuất đặc trưng từ ảnh nội soi và phân loại ảnh vào ba nhóm gồm normal, esophagitis và polyps. Việc sử dụng ResNet50 phù hợp với đặc điểm dữ liệu ảnh y khoa vì mô hình có khả năng học các đặc trưng phức tạp, đồng thời hạn chế hiện tượng suy giảm hiệu quả khi mạng có nhiều tầng.

Đề tài cũng thử nghiệm hướng kết hợp đặc trưng sâu từ ResNet50 với Linear SVM. Kết quả cho thấy đặc trưng trích xuất bởi mạng nơ-ron có thể được sử dụng cùng thuật toán học máy truyền thống để thực hiện phân loại. Tuy nhiên, ResNet50 thuần có lợi thế hơn về tính đơn giản trong triển khai và khả năng trả trực tiếp xác suất dự đoán cho từng lớp.

Đối với bài toán phân đoạn, DeepLabv3+ với encoder ResNet50 được áp dụng để xác định vị trí vùng polyp trên ảnh nội soi. Cách tiếp cận này giúp hệ thống không chỉ đưa ra nhãn dự đoán mà còn tạo mặt nạ và ảnh overlay trực quan, hỗ trợ người dùng quan sát vùng mà mô hình nhận định là bất thường. Về mặt lý thuyết, sự kết hợp giữa phân loại và phân đoạn giúp kết quả phân tích đầy đủ và dễ diễn giải hơn so với chỉ sử dụng một mô hình phân loại đơn thuần.

1.2 Kết luận về mặt thực nghiệm

Kết quả thực nghiệm cho thấy mô hình ResNet50 có khả năng phân loại tương đối tốt ba nhóm ảnh nội soi đã lựa chọn. Mô hình đạt validation accuracy tốt nhất khoảng 92,67% trong quá trình huấn luyện và đạt độ chính xác khoảng 88,22% trên tập kiểm thử.

Kết quả đánh giá theo từng lớp cho thấy lớp polyps được nhận diện tốt nhất, với F1-score đạt khoảng 97,66%. Hai lớp normal và esophagitis vẫn có một số trường hợp bị nhầm lẫn với nhau, cho thấy mô hình cần được cải thiện thêm về dữ liệu, khả năng học đặc trưng hoặc chiến lược huấn luyện để tăng độ ổn định trong các trường hợp có biểu hiện hình ảnh tương đồng.

Mô hình ResNet50 kết hợp Linear SVM cho kết quả tương đối gần với ResNet50 thuần, cho thấy hướng sử dụng đặc trưng học sâu kết hợp với thuật toán học máy truyền thống có tính khả thi. Tuy nhiên, trong phạm vi hệ thống hiện tại, ResNet50 thuần được ưu tiên sử dụng do quy trình dự đoán đơn giản và thuận tiện hơn khi tích hợp vào giao diện web.

Ở bài toán phân đoạn, DeepLabv3+ đã có thể tạo vùng mặt nạ và ảnh overlay cho các ảnh nghi ngờ có polyp. Kết quả này giúp hệ thống cung cấp thêm thông tin trực quan về vị trí tổn thương, thay vì chỉ hiển thị nhãn phân loại.

Ngoài phần mô hình, đề tài đã xây dựng được giao diện web hỗ trợ quy trình sử dụng cơ bản: nhập thông tin bệnh nhân, tải ảnh nội soi, chạy phân tích AI, xem kết quả dự đoán, xem vùng nghi ngờ, lưu hồ sơ và tra cứu lịch sử phân tích. Nhìn chung, hệ thống đã đáp ứng mục tiêu ban đầu của đề tài là xây dựng công cụ hỗ trợ phân tích ảnh nội soi dạ dày bằng AI, đồng thời tạo nền tảng để tiếp tục cải thiện dữ liệu, mô hình và khả năng ứng dụng thực tế sau này.

2. Hạn chế

Bên cạnh các kết quả đã đạt được, đề tài vẫn còn một số hạn chế cần được nhìn nhận rõ.

Thứ nhất, phạm vi phân loại của hệ thống hiện mới dừng ở ba nhóm là `normal`, `esophagitis` và `polyps`. Trong thực tế, ảnh nội soi đường tiêu hóa có thể liên quan đến nhiều bệnh lý khác như viêm dạ dày, loét dạ dày, xuất huyết, Barrett thực quản hoặc tổn thương nghi ngờ ung thư. Vì vậy, kết quả của hệ thống chỉ có ý nghĩa trong phạm vi các lớp dữ liệu đã được huấn luyện, chưa thể bao quát toàn bộ các bệnh lý tiêu hóa.

Thứ hai, dữ liệu sử dụng trong đồ án chủ yếu là dữ liệu đã được chuẩn bị từ các nguồn công khai hoặc nguồn nghiên cứu. Mặc dù dữ liệu có độ tin cậy và được gán nhãn, ảnh trong thực tế lâm sàng có thể khác nhiều về thiết bị nội soi, ánh sáng, góc chụp, độ phân giải, tình trạng phản sáng hoặc chất lượng chuẩn bị trước nội soi. Những khác biệt này có thể ảnh hưởng đến khả năng tổng quát hóa của mô hình khi áp dụng trên dữ liệu thực tế.

Thứ ba, mô hình phân loại vẫn còn nhầm lẫn giữa lớp `esophagitis` và `normal`. Kết quả từ ma trận nhầm lẫn cho thấy một số ảnh viêm thực quản bị dự đoán thành ảnh bình thường. Điều này có thể xuất phát từ việc một số ảnh viêm có biểu hiện chưa rõ ràng hoặc đặc trưng hình ảnh gần giống với ảnh bình thường. Đây là điểm cần cải thiện nếu muốn nâng cao độ tin cậy của hệ thống.

Thứ tư, quá trình huấn luyện ResNet50 có dấu hiệu overfitting ở các epoch sau. Train accuracy tăng cao và train loss giảm liên tục, trong khi validation loss có xu hướng tăng nhẹ sau giai đoạn đầu. Điều này cho thấy mô hình học rất tốt trên tập huấn luyện nhưng khả năng tổng quát hóa chưa tăng tương ứng trên tập validation.

Thứ năm, đối với bài toán phân đoạn polyp, kết quả mask có thể bị ảnh hưởng bởi các trường hợp polyp nhỏ, biên không rõ, bị che bởi dịch, bóng sáng hoặc các vùng phản chiếu trong ảnh nội soi. Những yếu tố này làm cho mô hình khó xác định chính xác ranh giới vùng tổn thương

Cuối cùng, hệ thống web hiện vẫn mang tính chất demo và phục vụ nghiên cứu. Lịch sử hồ sơ được lưu trên trình duyệt nên chưa phù hợp với yêu cầu lưu trữ dữ liệu y tế ở quy mô lớn. Hệ thống cũng chưa có các chức năng như đăng nhập, phân quyền người dùng, bảo mật dữ liệu bệnh nhân hoặc kết nối với cơ sở dữ liệu bệnh viện.

3. Hướng phát triển tương lai

Trong thời gian tới, đề tài có thể được phát triển theo một số hướng sau.

Trước hết, cần mở rộng dữ liệu huấn luyện với nhiều nguồn ảnh nội soi khác nhau. Việc bổ sung dữ liệu từ nhiều thiết bị, nhiều điều kiện ánh sáng và nhiều cơ sở y

tế sẽ giúp mô hình học được đặc trưng đa dạng hơn. Điều này có thể cải thiện khả năng tổng quát hóa khi áp dụng trên ảnh nội soi thực tế.

Thứ hai, nên mở rộng số lượng lớp bệnh lý mà hệ thống có thể nhận diện. Ngoài ba lớp hiện tại, hệ thống có thể được bổ sung thêm các nhóm như viêm dạ dày, loét dạ dày, xuất huyết tiêu hóa hoặc tổn thương nghi ngờ ác tính. Khi phạm vi lớp được mở rộng, hệ thống sẽ phù hợp hơn với mục tiêu hỗ trợ phân tích ảnh nội soi trong thực tế.

Thứ ba, có thể tiếp tục cải thiện mô hình phân loại bằng các kỹ thuật như tăng cường dữ liệu, fine-tune sâu hơn, sử dụng regularization, điều chỉnh learning rate hoặc thử nghiệm thêm các kiến trúc khác như EfficientNet, DenseNet hoặc Vision Transformer. Đặc biệt, cần tập trung giảm nhầm lẫn giữa lớp `esophagitis` và `normal`.

Thứ tư, đối với mô hình phân đoạn, có thể thử nghiệm thêm các kiến trúc như U-Net, Attention U-Net hoặc các biến thể mới hơn của DeepLab để so sánh với DeepLabv3+. Ngoài ra, việc điều chỉnh threshold, loss function và chiến lược augmentation cũng có thể giúp cải thiện chất lượng mask, nhất là với các polyp nhỏ hoặc vùng tổn thương có biên không rõ.

Thứ năm, hệ thống web nên được hoàn thiện thêm theo hướng ứng dụng thực tế hơn. Một số chức năng có thể phát triển tiếp gồm quản lý tài khoản, phân quyền bác sĩ/người dùng, lưu hồ sơ trên cơ sở dữ liệu, tìm kiếm lịch sử, bảo mật thông tin bệnh nhân và cải thiện nội dung báo cáo PDF.

Cuối cùng, nếu có điều kiện, hệ thống nên được đánh giá bởi bác sĩ chuyên khoa nội soi. Việc đối chiếu kết quả AI với nhận định của bác sĩ sẽ giúp kiểm tra mức độ phù hợp của mô hình trong thực tế, đồng thời cung cấp cơ sở để cải thiện hệ thống theo hướng an toàn và đáng tin cậy hơn.

Tóm lại, đồ án đã xây dựng được nền tảng ban đầu cho một hệ thống hỗ trợ phân tích ảnh nội soi bằng AI. Tuy nhiên, để có thể ứng dụng thực tế, hệ thống cần tiếp tục được mở rộng dữ liệu, cải thiện mô hình, tăng cường bảo mật và được đánh giá lâm sàng kỹ hơn.

TÀI LIỆU THAM KHẢO

- [1] Bộ Y tế, “15–20% người Việt mắc bệnh viêm loét dạ dày: Làm sao phát hiện sớm?”, *Sức khỏe & Đời sống*
- [2] M. Zamani, F. Ebrahimbtabar, V. Zamani, W. H. Miller, R. Alizadeh-Navaei, J. Shokri-Shirvani, and M. H. Derakhshan, "Systematic review with meta-analysis: the worldwide prevalence of *Helicobacter pylori* infection,"
- [3] International Agency for Research on Cancer (IARC), World Health Organization, *GLOBOCAN 2022: World Fact Sheet*. Lyon, France: Global Cancer Observatory, 2024.
- [4] International Agency for Research on Cancer (IARC), World Health Organization, *GLOBOCAN 2022: Viet Nam Fact Sheet*. Lyon, France: Global Cancer Observatory, Version 1.1, Feb. 2024.
- [5] L. C. Chen, Y. Zhu, G. Papandreou, F. Schroff, H. Adam, "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation", ECCV, 2018.
- [6] K. He, X. Zhang, S. Ren, J. Sun, "Deep Residual Learning for Image Recognition", CVPR, 2016.
- [7] C. Cortes, V. Vapnik, "Support-Vector Networks", Machine Learning, 1995.
- [8] https://link.springer.com/chapter/10.1007/978-3-030-01234-2_49
- [9] K. Pogorelov et al., "KVASIR: A Multi-Class Image Dataset for Computer Aided Gastrointestinal Disease Detection", MMSys, 2017.
- [10] D. Jha et al., "Kvasir-SEG: A Segmented Polyp Dataset", International Conference on Multimedia Modeling, 2020.
- [11] J. Silva et al., "Toward embedded detection of polyps in WCE images for early diagnosis of colorectal cancer", International Journal of Computer Assisted Radiology and Surgery, 2014.
- [12] TensorFlow, "TensorFlow Documentation".
- [13] PyTorch, "PyTorch Documentation".
- [14] FastAPI, "FastAPI Documentation".

